

西安交通大学

硕士学位论文

基于 3D Unet 头颈部 CT 图像器官分割的研究与应用

学位申请人：刘婷

指导教师：田丽华 高级工程师

合作导师：王文化 高级工程师

类别（领域）：工程硕士（软件工程）

2020 年 05 月

Research and Application on CT Image of Head and Neck Based on 3D Unet

A thesis submitted to
Xi'an Jiaotong University
in partial fulfillment of the requirements
for the degree of
Master of Software Engineering

By
Ting Liu
Supervisor: S.E. Lihua Tian
Associate Supervisor: S.E. Wenhua Wang
Master of Engineering (Software Engineering)
May 2020

摘 要

放疗是治疗头颈部肿瘤的主要方法，放射治疗时首先需要勾画出危及器官的轮廓，以便放疗师制定合理的照射剂量方案，减少放疗对正常组织的损伤。但是目前一般是由物理师手动勾画危及器官的轮廓，这种方式非常耗时且繁琐。为了减少医生的工作量，提高放射治疗的工作效率，实现头颈部 CT 图像器官的自动分割就成为了一个非常重要的研究方向。

本文旨在研究如何更有效地提高头颈部 CT 图像器官分割的精度，同时兼顾算法的执行效率。首先，本文提出了基于 3D Unet 的头颈部 CT 图像器官分割算法，对原始 3D Unet 从卷积深度、池化次数和损失函数三个方面进行改进，得到一个适合头颈部 CT 图像器官分割的网络模型。同时，本文引入 Two Stage 训练与分割流程，第一阶段的分割用于提取出器官的 bounding box，第二阶段进行各个器官与背景的像素级二分类，从而有效地提升了器官的分割精度。在本文数据集和 MICCAI 公开数据集上的实验结果表明：本文算法相比其他头颈部 CT 图像器官分割算法有更好的分割效果。然后，本文对基于 3D Unet 头颈部 CT 图像器官分割网络模型进行了模型压缩，依次对第一阶段的网络模型进行通道剪枝、阈值剪枝和权值量化。模型压缩后，其体积变为原来的 1/6，运行时占用的最大内存由原来的 3G 变为 2G，运行时间减少了 10s，而模型的分割精度保持不变。

本文主要围绕头颈部 CT 图像危及器官分割进行研究，提出了基于 3D Unet 头颈部 CT 图像器官分割算法和基于模型压缩的 3D Unet 头颈部 CT 图像器官分割算法，其分割精度及运行速度相比其他头颈部 CT 图像器官分割算法均有一定提升。

关 键 词：3D Unet；器官分割；CT 图像；剪枝；量化

论文类型：应用研究

ABSTRACT

Radiotherapy is the main method for the treatment of head and neck tumors. Radiotherapy needs to outline the organs at risk firstly so that the radiotherapist can formulate a reasonable radiation dose plan to reduce the damage to normal tissues. At present, doctors outline the organs at risk manually, which is very tedious and time-consuming. In order to reduce the workload of doctors and improve the efficiency of radiation therapy, automatic segmentation of head and neck CT images has become a very important research direction.

The purpose of this thesis is to study how to segment organs from h&n CT image to improve the accuracy, and the efficiency is considered. Firstly, an organ segmentation network is proposed, which improve the original 3D Unet from three aspects: convolution depth, number of pooling, and loss function. At the same time, two stage training and segmentation is introduced to improve the accuracy of organ segmentation. The segmentation in the first stage is used to extract the bounding box of organs, and the second stage focuses on pixel-level binary classification: organ and the background. Experiments on self datasets and MICCAI public datasets show that this thesis has better segmentation effect than other algorithms. Then, this thesis proposes a compressed model for h&n CT image organ segmentation, which performs channel pruning, threshold pruning, and weight quantization on the network model in the first stage. Experiments show that the size of compressed model changes to 1/6 of the original, the maximum running memory changes from 3G to 2G, the model's running time reduces by 10s, and the segmentation accuracy can be obtained.

This thesis focuses on how to effectively segment organs from h&n CT image. A model based on 3D Unet and a compressed 3D Unet for organ segmentation are proposed. Compared with other h&n CT image organ segmentation algorithms, this thesis has good improvements.

KEY WORDS: 3D Unet; Organ Segmentation; CT Image; Pruning; Quantization

TYPE OF THESIS: Application Research

目 录

摘要.....	I
ABSTRACT.....	II
1 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	2
1.3 论文的研究内容.....	3
1.4 论文的组织与结构.....	4
2 医学图像与深度学习图像分割技术.....	5
2.1 CT 图像.....	5
2.2 深度学习技术.....	6
2.2.1 FCN.....	6
2.2.2 Unet.....	7
2.2.3 3D Unet.....	7
2.2.4 模型压缩技术.....	8
2.3 深度学习技术在医学图像上的应用.....	10
2.4 评价标准.....	11
2.4.1 图像分割评价标准.....	11
2.4.2 模型压缩评价标准.....	12
2.5 本章小结.....	13
3 基于 3D Unet 头颈部 CT 图像器官分割算法的研究.....	14
3.1 头颈部 CT 图像器官分割算法分析.....	14
3.2 基于 3D Unet 头颈部 CT 图像器官分割算法的研究.....	16
3.2.1 数据预处理.....	16
3.2.2 Two Stage 训练与分割流程.....	19
3.2.3 神经网络整体结构.....	21
3.3 实验结果与分析.....	24
3.3.1 池化次数对分割精度的影响.....	24
3.3.2 卷积深度对分割精度的影响.....	25
3.3.3 损失函数对分割精度的影响.....	26
3.3.4 Two Stage 流程对分割精度的影响.....	27
3.3.5 算法对比与应用.....	30
3.4 本章小结.....	32
4 基于模型压缩的 3D Unet 头颈部 CT 图像器官分割算法的研究.....	33
4.1 基于 3D Unet 头颈部 CT 图像器官分割算法分析.....	33

4.2 基于模型压缩的 3D Unet 头颈部 CT 图像器官分割算法的研究	36
4.2.1 基于通道剪枝的 3D Unet 算法	36
4.2.2 基于阈值剪枝的 3D Unet 算法	39
4.2.3 基于多值化权值量化的 3D Unet 算法	42
4.3 实验结果与分析	45
4.3.1 通道剪枝对模型运行内存及速度的影响	45
4.3.2 阈值剪枝对模型稀疏度的影响	46
4.3.3 量化对模型体积的影响	47
4.4 本章小结	48
5 结论与展望	49
5.1 结论	49
5.2 展望	50
致 谢	51
参考文献	52

CONTENTS

ABSTRACT(Chinses).....	I
ABSTRACT(English).....	II
1 Introduction	1
1.1 Background and Significance.....	1
1.2 Research Actuality.....	2
1.3 Study of Present Dissertation	3
1.4 Organization of Thesis	4
2 Medical Image and Deep Learning Techniques of Image Segmentation	5
2.1 CT Image.....	5
2.2 Deep Learning Techniques.....	6
2.2.1 FCN	6
2.2.2 Unet	7
2.2.3 3D Unet	7
2.2.4 Model Compression Techniques	8
2.3 Application of Deep Learning on Medical Image.....	10
2.4 Evaluation Standard	11
2.4.1 Evaluation Standard for Image Segmentation.....	11
2.4.2 Evaluation Standard for Model Compression	12
2.5 Summary	13
3 Research on H&N CT Image Organ Segmentation Algorithm Based on 3D Unet	14
3.1 Analysis of Existing H&N CT Image Organ Segmentation Algorithm.....	14
3.2 Research on H&N CT Image Organ Segmentation Algorithm Based on 3D Unet	16
3.2.1 Data Preprocessing	16
3.2.2 Two Stage Training and Segmentation Process	19
3.2.3 Neural Network Structure	21
3.3 Experimental Results and Analysis	24
3.3.1 Effect of Pooling Times on Segmentation Accuracy	24
3.3.2 Effect of Convolutional Depth on Segmentation Accuracy	25
3.3.3 Effect of Loss Function on Segmentation Accuracy	26
3.3.4 Effect of Two Stage Process on Segmentation Accuracy	27
3.3.5 Algorithm Comparison and Application	30
3.4 Summary	32
4 Research on 3D Unet Organ Segmentation Algorithm Based on Model Compression.....	33
4.1 Analysis of H&N CT Image Organ Segmentaion Algorithm Based on 3D Unet.....	33
4.2 Research on 3D Unet Organ Segmentation Based on Model Compression	36
4.2.1 3D Unet Algorithm Based on Channel Pruning	36
4.2.2 3D Unet Algorithm Based on Threshold Pruning	39
4.2.3 3D Unet Algorithm Based on Multi-valued Weight Quantization.....	42

4.3 Experimental Results and Analysis	45
4.3.1 Effect of Channel Pruning on Model Running Memory and Speed	45
4.3.2 Effect of Threshold Pruning on Model Sparsity	46
4.3.3 Effect of Quantization on Model Volume.....	47
4.4 Summary	48
5 Conclusions and Suggestions	49
5.1 Conclusions	49
5.2 Suggestions.....	50
Acknowledgements	51
References	52

1 绪论

1.1 研究背景与意义

头部或颈部的恶性肿瘤统称为头颈癌（head and neck cancer, HNC），是世界上最常见的癌症之一，全球每年约有50万病例^[1]。由于肿瘤和危及器官的复杂位置和形状，放疗是治疗头颈癌的主要方法^[2]。放射治疗过程中，利用高能射线杀死癌细胞使肿瘤变小或消失，照射时需避开肿瘤周围的器官（Organs at risk, OARs），以免损伤正常组织。

头颈部肿瘤放射治疗过程中，首先，由物理师在CT图像上勾画出肿瘤和危及器官，然后，放疗师根据勾画的区域计算照射分布和靶区照射剂量^[3]。为了尽量减少放射治疗后的并发症，降低辐射引起正常组织癌变的风险，脑干、眼睛、视神经、下颌骨和腮腺等危及器官必须准确勾画^[4]。

目前，通常由物理师手动勾画出危及器官和肿瘤的轮廓。CT图像通常是由几十甚至上百张二维图像堆叠而成，且头颈部的危及器官非常多，一个有经验的医生勾画出头颈部CT图像上的全部器官需花费两个小时或更长时间^[5]，手工勾画是非常耗时且繁琐的。此外，由于不同的医生有不同的勾画标准和风格，勾画出的器官往往具有差异性，这些差异性会影响放疗的效果。

计算机自动分割算法具有解决上述问题的潜力，但迄今为止，应用在医院的自动分割算法的结果远不如一个有经验的医生。目前，大多数分割算法都是基于Atlas的^[6]，通过手工标记的训练样例推断出新的样本分割。基于Atlas的分割算法无法充分考虑不同患者之间器官的可变性，特别是考虑到肿瘤对器官的影响时，因此，其分割结果较差，需要人类专家大量编辑调整才能应用^[7]。综上，基于Atlas的分割算法未能显著改善CT图像危及器官自动分割这一难题^{[8][9]}。

近年来，相比传统图像分割方法，基于深度学习的图像分割方法能够取得更好的分割效果^[10]。在医学图像分割领域，U-Net^[11]卷积网络结构取得了显著的成就^[12]。在头颈部CT图像器官分割领域，越来越多基于深度学习的分割方法被提出，其中，一部分学者使用基于patches的分类网络^[13]进行分割；另一部分学者使用基于U-Net的体系结构^{[14][15][16][17]}进行分割。

尽管基于深度学习的分割算法提供了希望，但其分割结果与人类专家相比，仍然存在较大偏差。因此，如何基于深度学习算法得到较好的分割结果仍是头颈部CT图像器官分割领域的一大难题。CT图像中软组织对比度较低，危及器官与周围组织分界不是很明显，分割难度较大；而且，器官占整张CT图像的比例相对较小，器官大小、形状、体积差异性较大等因素，导致分割出的精确度也差异较大，例如：下颌骨分割结果的dice系数可达到93%，而左右视神经分割结果的dice系数只有10%左右。综上，很多基于深度学习的CT图像危及器官自动分割算法尚未达到应用在医院的水准，存在提升空间。

本文主要是分割头颈部CT图像的八个器官，分别是：脑干、左右眼睛、左右视神经、左右腮腺、下颌骨。为了解决上述问题，在3D Unet神经网络结构的基础上，做了以下几点创新和改进。首先，从卷积深度、池化层数和损失函数三个方面改进原始3D Unet，得到一个适用于头颈部CT图像器官分割的神经网络模型。其次，引入Two Stage训练与分割流程，基于3D Unet完成一次分割或训练之后，不直接应用其结果，而是提取分割出的器官的bounding box，做第二次分割或训练，达到提升各个器官分割精度的目的。最后，本文将剪枝与量化模型压缩方法应用在3D Unet模型上，减少分割所花费的时间及内存占用。这些研究不仅解决实际中的应用问题，也具有深远的研究和现实意义。

1.2 国内外研究现状

为了解决头颈部CT图像器官自动分割这一难题，在过去的几十年，学者们提出了很多危及器官自动分割算法，这些算法主要分为四类。接下来将对这四类算法涉及到的相关工作进行简短的介绍，主要用来反映当下头颈部CT图像器官分割算法使用的技术与发展方向。

1) 基于图谱的危及器官分割 (atlas-based method)

基于图谱的分割算法充分利用 CT 图像中危及器官的位置相对固定、不同人的器官外观相似等特点，将图像分割转变为图像配准。基于单图谱的危及器官分割算法仅含有一个模板，即：只有一个带器官标注信息的 CT 图像，将其与目标图像进行配准，得到模板图像到目标图像的变换参数，然后把变换参数应用于模板标注，得到目标图像的分割结果。基于单图谱的分割算法只与一个带标注的图像进行配准，当目标图像与模板图像差异较大时，得到的分割结果也较差。目前比较流行的是基于多图谱的分割方法，当存在多个模板时，可以将目标图像与模板图像进行比对选择最佳的模板进行配准^[18]，也可以将目标图像分别与模板图像配准，融合多个配准结果得到变换参数。基于 Atlas 的分割方法仍然非常流行，是目前应用最广泛的医学图像分割方法，但其瓶颈在于使用固定的模板数据库去处理不同患者的分割问题。此外，它是计算密集型的，即使使用最有效的实现，完成一个配准任务也需要几分钟时间^[19]。

2) 基于模型的危及器官分割 (model-based method)

基于统计形状模型 (Statistical Shape Model, SSM) 的分割算法建立模型时依据不同器官的形状以及变化规律不同，基于统计外观模型 (Statistical Appearance Model, SAM) 的分割算法建立模型时依据不同器官在 CT 图像中的灰度分布以及变化规律不同，由于添加了先验约束，利用 SSM 和 SAM 可以显著地提升分割精度。Buzug 等^[20]使用 SSM 成功地从 CT 图像中分割出了下颌骨。基于 SSM 和 SAM 的分割算法限制了特定的统计模型形状，分割结果往往不够灵活并且高度依赖训练集样本。Fritscher 等^[21]结合了 SSM 和基于图谱的分割方法，实现了左右腮腺和脑干的分割。活动形状模型 (Active Shape Model, ASM) 最早是在 1995 年被提出的，chen 等^[22]利用基于活动形状

模型的算法成功地从 CT 图像中分割出了左右腮腺。相比活动形状模型,活动外观模型 (Active Appearance Model, AAM) 包括纹理特征,可以取得更好的分割结果。

3) 基于分类的危及器官分割

基于分类的分割算法通过训练一个分类器有效地处理大量高维的训练数据,常用的较简单的分类器有贝叶斯分类器 (Bayes classifier) 和逻辑回归 (logistics regression)。Qazi 等^[23]提取待分割图像的特征,利用 k 近邻 (K-Nearest Neighbors, KNN) 算法完成了对下颌骨、脑干、腮腺的分类。Ma 等^[24]利用非线性分类森林自动融合图像和标签信息进行大脑分割。Wachinger 等^[25]结合图像块局部灰度、位置信息以及图像特征成功地从 CT 图像中分割出了左右腮腺。

4) 基于深度学习的危及器官分割

近年来,针对头颈部 CT 图像危及器官自动分割这一难题很多深度学习方法被提出,如全卷积神经网络 (FCN^[26])、Unet 和生成对抗网络 (GAN^[27])。Tong 等^[28]将传统分割方法与深度学习方法相结合,完成了对头颈部 CT 图像中九个危及器官的分割。Ibragimov 等^[29]在头颈部 CT 图像上分别提取目标器官图像块及目标器官周围组织图像块输入神经网络,为每个器官训练专属自己的神经网络模型。Men 等^[30]采用 Two Stage 的 2D/3D 卷积神经网络模型先对器官的大致区域进行定位,再进行分割,分割出的器官轮廓更接近于手工标注。

1.3 论文的研究内容

目前,放疗是治疗头颈癌的主流方法。在放射治疗中,第一步也是最关键的一步是勾画出肿瘤和危及器官的轮廓,以便放疗师根据肿瘤和器官的位置和体积制定放射方案。本文主要研究分割头颈部CT图像的八个器官,分别是:脑干、左右眼睛、左右视神经、左右腮腺、下颌骨,主要研究目标包括:1) 提升八个器官分割的整体精确度;2) 提升小器官(左右视神经)的分割精确度;3) 减少分割所花费的时间和占用的内存。本文基于当下流行的深度卷积网络3D Unet,从提升分割精度、减少模型运行时间内存占用两个方面做改进:

1) 提出一种基于改进的 3D Unet 头颈部 CT 图像器官分割算法:为了得到一个适用于头颈部 CT 图像器官分割的神经网络模型,从卷积深度、池化层数和损失函数三个方面改进原始 3D Unet;为了提升器官的分割精确度,引入 Two Stage 训练与分割流程,第一阶段训练并得到一次性分割出八个器官的网络模型,第二阶段从第一阶段的分割结果中提取出各个器官的 bounding box,分别为每个器官训练分割模型,

2) 提出一种基于模型压缩的3D Unet头颈部CT图像器官分割算法:首先,为了减少模型的内存占用及分割所花费的时间,对改进后的3D Unet进行通道剪枝;其次,为了配合硬件存储、加速相关工作,对通道剪枝后的模型进行阈值剪枝,提高模型的稀疏度;最后,对剪枝后的模型进行量化,减少模型中权值所占的位数,从而减少模型的内存占用、配合硬件加速。

1.4 论文的组织与结构

本文主要分为 5 章，结构安排如下：

第 1 章，绪论：主要对头颈部 CT 图像器官分割算法的研究背景及意义进行介绍，对 CT 图像器官分割的应用领域、研究现状做了简要的说明，最后给出本文主要工作内容以及论文的组织结构。

第 2 章，医学图像与深度学习图像分割技术：首先简单介绍 CT 图像；其次介绍深度学习图像分割技术、模型压缩技术以及深度学习图像分割技术在医学图像上的应用；最后介绍图像分割及模型压缩的评价标准。

第 3 章，基于 3D Unet 头颈部 CT 图像器官分割算法的研究：从卷积深度、池化层数和损失函数三个方面改进 3D Unet，得到适合头颈部 CT 图像器官分割的网络模型；引入 Two Stage 训练与分割流程，提高器官分割的精确度。

第 4 章，基于模型压缩的 3D Unet 头颈部 CT 图像器官分割算法的研究：首先对模型进行通道剪枝，减少模型的内存占用及运行时间；其次，对通道剪枝后的模型进行阈值剪枝，提高模型的稀疏度；最后，对剪枝后的模型进行权值量化，减少模型的内存占用，配合硬件存储、加速相关工作。

第 5 章，结论与展望：分析本文算法的不足之处，对下一步的研究方向进行展望。

2 医学图像与深度学习图像分割技术

上一章主要介绍了头颈部 CT 图像器官分割的研究背景与意义、国内外研究现状。在此基础上,本章着重介绍 CT 图像、深度学习图像分割和模型压缩技术、深度学习技术在医学图像上的应用以及相关评价标准,为后续工作提供理论基础。

2.1 CT 图像

CT (Computed Tomography) 是计算机断层扫描的简称,在医学、工业、物理等多学科领域发挥着重要的作用。本文中出现的 CT 指的是 X 光 CT,是以 X 光为放射源对人体组织特定厚度的层面进行扫描。X 光是一种高能射线,在穿透人体组织时与人体组织发生核反应导致部分能力被吸收。不同组织与 X 光发生核反应的强弱不同,所以对 X 光的吸收能力不同,通过计算穿过人体前后的能量差可以得到不同组织对 X 光的吸收值,即:CT 值。将 CT 值按照一定顺序排列成数字矩阵,由计算机处理后显示到输出设备上,就得到了 CT 图像。

现实生活中,很容易混淆 CT 与传统 X 光的概念,二者既有区别又有联系。相同点在于二者都利用人体不同组织(如:骨头、血液、神经等)对 X 线吸收能力不同的特性,不同点主要在于:1) 成像原理不同。X 光检测是输出 X 射线被人体组织吸收之后落在探测器上的图像,只形成了一张影像;而 CT 检测是一层一层穿过人体检测的,形成了很多张图像,这一系列图像经过计算机整合处理后,可以从多个维度观察组织结构,也可以反映人体的三维形态。2) 应用类型不同。X 光检测大约只能区分 20 级密度;CT 检测能区分的密度范围更广(2000 级以上),器官和结构显影清晰,病变可以被清楚地显示出来。

一般来说,进行一次 CT 检测,得到的是一个三维图像。该三维图像由几十甚至上百张二维图像堆叠而成,CT 检测时,扫描层厚设置的越薄,二维 CT 图像就越多。CT 图像以 Hounsfield Unit (Hu) 为单位,以水的 CT 值为基准,即水的 CT 值为 0;吸收 X 光强于水的组织,其 CT 值为正;吸收 X 光弱于水的组织,其 CT 值为负。约定 CT 值的上界和下界分别是 1000 (骨皮质) 和 -1000 (空气)。

国际上通用的医学影像传输协议是 DICOM (Digital Imaging and Communications in Medicine),不同医院都按照这个标准存储图像。基于 DICOM3.0 标准的医学图像中,每一张图像都携带许多信息,除了患者的 CT 值,还包括 CT 设备、检测时人为设置的相关参数、检测时间等信息。这些信息主要可以分为 Patient, Study, Series 和 Image 四类。每个 DICOM Tag 由两个数字(十六进制)组合而成,分别为 Group 和 Element。如(0010,0010)这个 Tag 表示的是 Patient's Name,存储患者的姓名。在研究医学图像时,需要解析 dicom 获取需要的信息。

DICOM 是以人为绝对坐标系的,X 轴是右手边指向左手边;Y 轴是前胸指向后背;

Z 轴是脚指向头部。以下是解析 DICOM 文件时，主要用到的参数：1) PatientPosition: 描述病人相对于 CT 成像设备的位置。HFP: 头部在前，俯卧；HFS: 头部在前，仰卧。2) ImagePosition: 图像左上角第一个像素的坐标 (x, y, z)，也是 dicom 文件传输的第一个 CT 值坐标。3) RescaleSlope 和 RescaleIntercept: 所处理的 dicom 图像一般是经过量化后的灰度图像，可依据 $Hu = pixelVal * RescaleSlope + RescaleIntercept$ ，将像素值转化为 CT 值。4) PixelSpacing: 校正或修正后的像素间距。5) SliceThickness: Z 轴的扫描分辨率。

2.2 深度学习技术

2.2.1 FCN

2015 年, Long J 等^[26]提出的全卷积网络模型(Fully Convolutional Networks, FCN)是语义分割领域的一个里程碑。在 FCN 出现之前, 传统的 CNN 分割是将像素周围的小区域喂入神经网络进行训练和预测, 由于小区域数量极多, 操作起来非常低效; 此外, 训练时只关注小区域内的特征, 忽略了整体的信息, 导致分割结果不是很精确。

传统 CNN 网络, 一般在卷积层后面接上若干个全连接层, 最后输出一个固定长度的特征向量, 进行分类。如: 输出一个 100 维的向量, 每个维度表示输入图像属于某一类别的概率。FCN 没有全连接层, 它对最后一个卷积层进行上采样(转置卷积), 输出一个与原图大小相同的特征图, 对每一个像素进行类别预测, 得到输入图像中每一个像素属于某一类别的概率, 如图 2-1 所示。

FCN 中使用转置(反)卷积把特征图的大小变为与输入图像一致, 插值法(最近邻插值、双线性插值等)也可以实现把特征图的大小变为与原图一致的目的, 但基于插值法实现的上采样, 需要在决定网络结构时决定使用某种固定的插值方法进行插值, CNN 模型不能自己学习更优地插值。转置卷积操作构建了一种和普通卷积操作一样的连接关系, 拥有可以学习的参数, 不必预先定义插值方法, 可以通过神经网络的自我学习得到一种适合自身的最优的上采样方法。

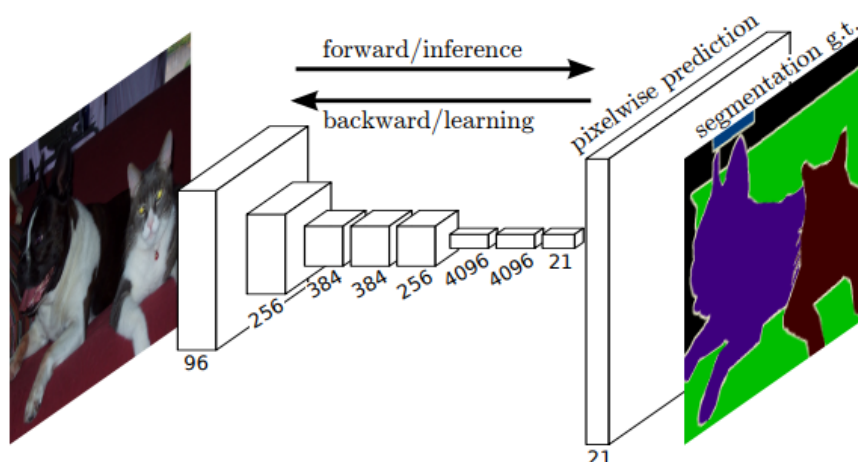


图 2-1 FCN 示意图

2.2.2 Unet

上一小节提到，FCN 对最后一个卷积层进行上采样恢复到原图大小，仅对最后一个特征图进行操作，明显会丢失很多信息。FCN 采取的解决方法是：将不同特征图对应元素相加，再进行上采样。这样做的缺点是分割结果的细节不够好。

Unet 结构如图 2-2 所示，蓝色箭头表示对上一层特征图进行 3×3 的卷积，并对其使用 **relu** 激活函数；红色箭头表示对上一层特征图进行 2×2 的最大池化；绿色箭头表示对上一层特征图进行 2×2 的转置卷积。与 FCN 不同的是：1) Unet 是完全对称的，其池化次数与转置卷积次数相同，每个由最大池化得到的特征图 shape 都有与之对应的转置卷积之后的特征图 shape；2) 在融合特征时，Unet 将最大池化后的特征图与转置卷积卷积后的特征图拼接起来，使得降采样阶段的特征可以直接在上采样阶段复用，保证了浅层信息与深层信息的融合。所以，Unet 定位更精确，分割效果也更好。

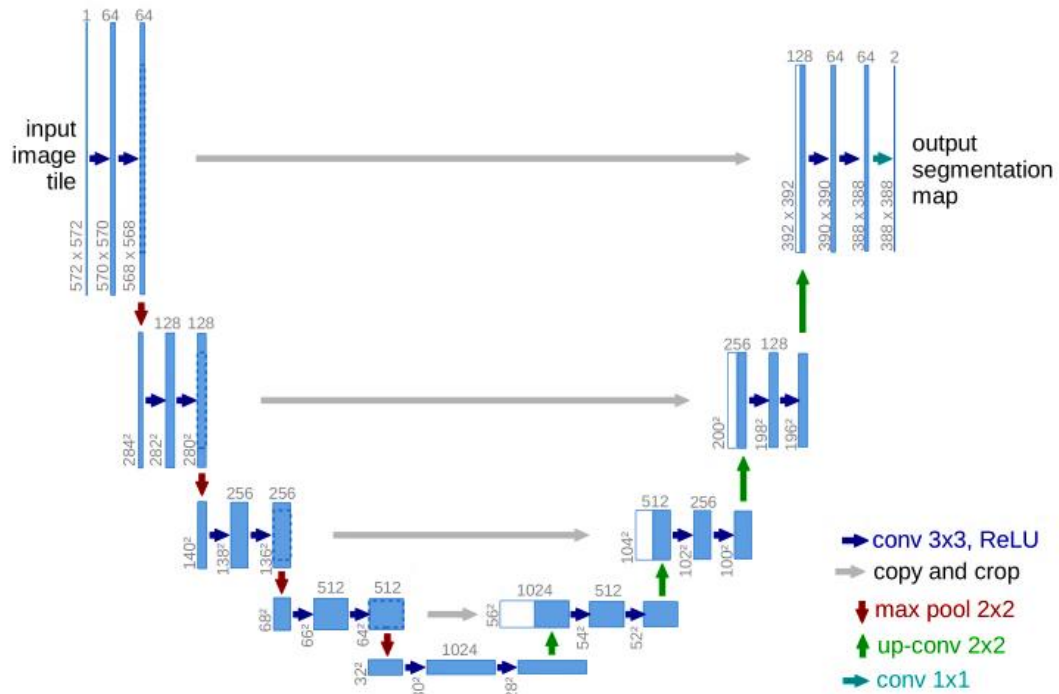


图 2-2 Unet 网络结构图

相比自然界图像，医学图像存在以下特点：1) 数量少。2) 医学图像边界模糊、梯度复杂。3) 人体内部结构相对固定，分割目标在人体图像中的分布具有规律性，语义较简单。Unet 神经网络在医学图像分割中表现良好依赖于其能够结合浅层和深层信息的特性，利用融合浅层特征改善了上采样信息的不足。深层信息，指多次卷积操作后的低分辨率信息，能够提供分割目标在整个图像中语义信息，有助于判断物体的类别。浅层信息，指最初几次卷积获取的高分辨率信息，能够提供精细的特征，如：梯度、纹理等，用于精准分割。

2.2.3 3D Unet

2016 年，Cicek O 等^[31]提出的 3D Unet、Milletari F 等^[32]提出的 Vnet 是 Unet 网络结构的一种 3D 变形，主要思想是直接使用 3D 卷积核对三维图像进行卷积，并引入

BN^[33]。使神经网络可以更快地收敛。3D Unet 只需要少部分 2D 的标注切片就可以生成密集的立体分割，其主要创新点是：1）在稀疏标注（三维图像中某些截面未进行标注）的数据集上训练并预测此数据集上未标注的地方；2）在稀疏标注的数据集上训练并预测新的数据。

关于使用 2D、3D 还是“2.5D”神经网络模型，也是一个热门的研究领域。在不考虑硬件设备（如：GPU）的前提下，相比二维卷积，三维卷积多一个维度的信息（层间信息）可以利用，会取得更优的效果。3D 网络的劣势在于显存占用，这导致不可能将整个三维图像直接输入神经网络，必须对图像进行剪切，剪切会丢失一部分图像信息。3D 网络对硬件设备要求高、内存占用量大、训练和检测时花费时间较长，这些都会影响算法的适用性，因此，减少模型参数和计算量，压缩模型尺寸，加快模型运算速度，具有重要的现实意义。

2.2.4 模型压缩技术

自 2012 年 AlexNet 以来，卷积神经网络在图像分类、分割、目标检测等领域获得了广泛的应用。随着学者们对分类或分割结果的要求越来越高，卷积神经网络的层数不断增加，如：ResNet 和 DenseNet 进行了上千次的卷积操作。分类或分割的结果得到了提升，但上千层的网络带来了效率问题。效率问题主要是模型存储时占用内存大和模型运行耗时。只有解决效率问题，才能更广泛的应用 CNN。

对于效率问题，设计轻量化模型是一种不错的解决办法。为了得到轻量化模型，需要设计更高效的计算方式，且需要保证：在减少参数的情况下，不损失网络模型分类或分割的精度。相比轻量化模型，模型压缩（Model Compression）是处理已经训练好的模型，使模型携带更少的参数或参数占用更少的存储比特数，从而减少模型内存占用，加速网络模型的计算。以下介绍当下比较常见的模型压缩方法：

1) 参数共享

参数共享或权值共享主要是通过让网络中多个参数共享同一值来减少网络的参数量，从而减少网络的内存占用^[34]。Han 等^[35]使用 k 均值聚类的方法进行参数共享，对训练好的模型，以 k 均值聚类的方式将每一层神经网络的参数分为不同簇，为相同簇的参数设置权值用于共享。其他参数共享算法在实际操作中也大都依赖“k 均值”，如果 k 均值聚类算法没有很好地发挥作用，模型的最终结果会变得很差。此外，使用权值共享方法将模型压缩到非常小会造成非常大的精度损失。

2) 量化

量化通过减少存储参数的比特数达到模型压缩的目的，包括两种方法：低精度和重编码^[36]。Tensorflow 中，神经网络模型的参数一般用 float32 存储，低精度方法使用 float16、float8、int8 等存储参数；重编码方法对模型中的参数、权值等重新编码，用更少的位数去表示，从而实现模型压缩。二值化网络是量化的极端情况，用+1 和-1 表示模型中的所有参数，卷积过程中所有的乘法运算用加法和取反操作替代。二值化网络极大地减少了模型的存储空间，但模型精度也损失很大。

3) 剪枝

神经网络的参数量往往非常多，且其中大部分的参数在训练好之后趋于零，对整个网络的贡献可以忽略不计。剪枝通过设定合理的评判标准裁剪网络中一些不重要的 connection 或者 filter 来减少参数冗余，是神经网络模型压缩领域一种广泛使用的方法^[37]。从剪枝粒度角度，可以把剪枝算法分为细粒度剪枝和粗粒度剪枝。细粒度 (element-wise) 剪枝是指对单个权重的剪枝，仅把元素置为零，不会改变神经网络的初始结构，又称为非结构化剪枝；粗粒度剪枝是指对卷积核中的某维向量或整个卷积核进行剪枝，会改变原始神经网络结构，又称为结构化剪枝。

从剪枝流程角度，可以把剪枝算法分为一次性剪枝和迭代剪枝。剪枝流程一般分为：计算权值的重要性；剪掉对神经网络影响不大的权值；对剪枝后的网络进行再训练。图 2-3 左边是一次性剪枝，一次性剪枝仅对模型进行一次剪枝和重训练。图 2-3 右边是文中使用的迭代剪枝，当对神经网络模型进行一次剪枝和重训练后，会判断是否达到剪枝终止条件，未达到终止条件时，会再次计算模型中不重要的权重进行剪枝和重训练。迭代剪枝可以反复学习哪些权重是重要的，根据评判标准剪去最不重要的权重，然后对模型进行重训练，调整权重使其从剪枝中“恢复”。迭代剪枝中每次迭代都会剪掉更多的权重，理论上，可以得到更“瘦小”的模型。

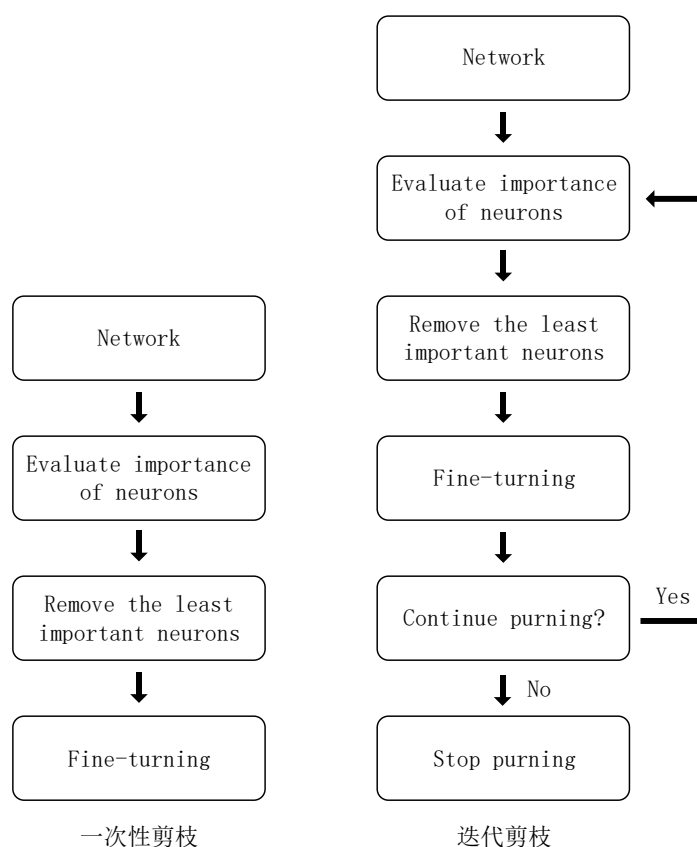


图 2-3 一次性剪枝与迭代剪枝流程

4) 低秩分解

一个典型的 CNN 卷积核是四维张量，一个全连接层可以看作是二维张量，低秩分

解的中心思想是奇异值分解 (Singular Value Decomposition, SVD), 用少数基表示权值矩阵。低秩分解方法涉及大量的矩阵操作, 需要相关人员具备非常专业的数学知识, 实现起来不是很简单。此外, 目前的低秩分解方法大都是按层来进行的, 不同层之间的信息不能共享, 存在信息“阻塞”的问题。

5) 知识蒸馏

网络蒸馏或知识蒸馏 (knowledge distillation, KD) 主要思想是将大模型学习到的“知识”迁移到小模型上, 小模型模拟大模型学习到的类分布输出。基于知识蒸馏的方法能使更深的模型变得更浅, 从而显著地降低计算成本, 但是也存在一些缺点, 例如: 只能用于含有 Softmax 函数的任务, 严重地阻碍了其应用。

2.3 深度学习技术在医学图像上的应用

近十年, 基于深度学习的医学图像分析与处理是一门发展迅速的交叉学科, 图像分类、检测、分割和生成等作为深度学习处理的关键问题, 在医学领域中也具有重要的意义, 下面分别进行介绍:

1) 分类

深度学习在医学图像分类领域做出了重大的贡献。在医学图像分类中, 通常输入一张或多张图像, 输出单个诊断变量 (例如: 是否存在疾病)。在这种情况下, 每次诊断检查所得的图像都是一个样本, 与计算机视觉中的数据集相比, 医疗图像数据集通常较小, 仅有成百上千个样本或数百万个样本, 也因此, 在医学图像分类中, 迁移学习非常流行。

2) 检测

对图像中感兴趣的目标或病变的检测是医疗诊断的关键部分, 也是临床医生最费力的工作之一。帮助医生定位病变和识别病变是医学图像检测的主要任务之一。计算机辅助检测 (computer-aided detection, CAD) 有着悠久的历史, 主要用来定位病变, 减少人类专家的工作量。1995 年, 第一个使用 CNN 的辅助检测系统被提出, 该系统使用四层 CNN 来检测 X 射线图像中的结节^[38]。

3) 分割

医学图像中组织分割 (如: 器官与周围组织的分割, 病变组织与正常组织的分割等) 可以有效地帮助医生定量分析。而且, 分割是 CAD 流程中的第一步。分割任务通常定义为识别感兴趣目标的轮廓或内部的体素集。基于深度学习的医学图像分割是最热门的研究主题, 因此, 基于深度学习的分割方法得到了最广泛的应用, 包括开发基于 CNN 的独特分割架构以及 RNN 框架。

4) 配准

医学图像配准 (Medical image registration) 指一种模式的图像 (如: MRI) 到另一种模式的图像 (如: CT) 的坐标变换, 是一种常见的图像分析任务。配准任务通常是在迭代框架中执行的, 包括假定特定类型的 (非) 参数变换并优化预定度量 (例如:

L2 范数)。尽管分割和病灶检测是深度学习的热门话题，但研究人员发现深度学习有利于获得最佳的配准性能。在当前文献中普遍存在两种配准策略：（1）使用深度学习网络估计两个图像的相似度以驱动迭代优化策略；（2）使用深度回归网络直接预测变换参数。

2.4 评价标准

2.4.1 图像分割评价标准

图像分割中通常使用许多标准来衡量算法的精确度，被广大研究者认可与使用的度量方法主要有以下五种，分别是像素准确率、平均像素准确率、均交并比、频权交并比和 Dice 系数：

1) 像素准确率 (Pixel Accuracy, PA)，是一种最简单的度量方法，计算预测正确的像素占总像素的比例，如式 2-1：

$$PA = \frac{\sum_{i=0}^k P_{ii}}{\sum_{i=0}^k \sum_{j=0}^k P_{ij}} \quad (2-1)$$

式中， P_{ii} 表示预测正确的数量， P_{ij} ($i \neq j$) 表示预测错误的数量。

2) 平均像素准确率 (Mean Pixel Accuracy, MPA)，计算每一个类别的 PA，取所有 PA 的均值作为最终结果，如式 2-2：

$$MPA = \frac{1}{k+1} \sum_{i=0}^k \frac{P_{ii}}{\sum_{j=0}^k P_{ij}} \quad (2-2)$$

式中， P_{ii} 表示预测正确的数量， P_{ij} ($i \neq j$) 表示预测错误的数量， k 表示一共有多少类， $k+1$ 表示包括背景。

3) 均交并比 (Mean Intersection over Union, MIoU)，是语义分割的标准度量。用两个集合的交集除以并集，这两个集合分别指标注值 (ground truth) 和预测值 (predicted segmentation)。在每个类上计算 IoU，之后平均，如式 2-3：

$$MIoU = \frac{1}{k+1} \sum_{i=0}^k \frac{P_{ii}}{\sum_{j=0}^k P_{ij} + \sum_{j=0}^k P_{ji} - P_{ii}} \quad (2-3)$$

式中， P_{ii} 表示预测正确的数量， P_{ij} ($i \neq j$) 表示本属于类 i 但被预测为类 j 的数量， P_{ji} ($i \neq j$) 表示本属于类 j 但被预测为类 i 的数量， k 表示一共有多少类， $k+1$ 表示包括背景。其中， $\frac{P_{ii}}{\sum_{j=0}^k P_{ij} + \sum_{j=0}^k P_{ji} - P_{ii}}$ 又可简单表示为式 2-4：

$$IoU = \frac{|A \cap B|}{|A \cup B|} \quad (2-4)$$

式中， A 和 B 分别指某一类的真实值 (ground truth) 集合和预测值 (predicted segmentation) 集合。

4) 频权交并比 (Frequency Weighted Intersection over Union, FWIoU)，对均交

并比进行了改进，均交并比求每一类 IoU 的平均值，而频权交并比求每一类 IoU 的加权平均值，如式 2-5：

$$FWIoU = \frac{1}{\sum_{i=0}^k \sum_{j=0}^k P_{ij}} \sum_{i=0}^k \frac{P_{ii}}{\sum_{j=0}^k P_{ij} + \sum_{j=0}^k P_{ji} - P_{ii}} \quad (2-5)$$

式中， P_{ii} 表示预测正确的数量， P_{ij} ($i \neq j$) 表示本属于类 i 但被预测为类 j 的数量， P_{ji} ($i \neq j$) 表示本属于类 j 但被预测为类 i 的数量， $k+1$ 表示一共有多少类（包括背景）。

5) Dice 系数，是一种集合相似度度量函数，用于计算两个样本的相似程度，取值范围在 0-1 之间，如式 2-6：

$$Dice = \frac{2|A \cap B|}{|A| + |B|} \quad (2-6)$$

式中，A 和 B 分别指真实值（ground truth）和预测值（predicted segmentation）。

2.4.2 模型压缩评价标准

模型压缩使用的方法不同，其评价标准也有所不同，下面主要介绍模型剪枝和量化的评价标准。

剪枝的评价标准主要有以下两种：

1) 对比神经网络压缩前后模型的大小，计算压缩率，如式 2-7：

$$c = \frac{m_o - m_i}{m_i} \quad (2-7)$$

式中， m_o 表示剪枝后模型的大小， m_i 表示剪枝前模型的大小， c 表示模型的压缩率。

2) 对比神经网络压缩前后模型的检测时间，计算速度的提升率，如式 2-8：

$$s = \frac{t_i - t_o}{t_i} \quad (2-8)$$

式中， t_i 表示剪枝前模型的运行时间， t_o 表示剪枝后模型的运行时间， s 表示模型的速度提升率。

3) 对比浮点运算量（FLOPs: Floating point operations），卷积层（考虑 bias）的 FLOPs 计算如式 2-9：

$$FLOPs = (2 \times C_i \times K^2) \times H \times W \times C_o \quad (2-9)$$

式中， C_i 表示输入特征图的通道数， K 表示卷积核的大小， H 表示输出特征图的高， W 代表输出特征图的宽度， C_o 代表输出特征图的通道数。

量化的评价标准主要是量化后与量化前 GPU 上存储的模型大小之比，如式 2-10：

$$s = \frac{b_o}{b_i} \quad (2-10)$$

式中， b_o 表示量化后模型中的参数所占的比特数， b_i 表示量化前模型中的参数所占的比特数，一般是 float32。

2.5 本章小结

本章主要介绍 CT 图像、深度学习技术、深度学习技术在医学图像上的应用以及相关评价标准。深度学习技术主要介绍当下医学领域中比较流行的分割框架和模型压缩技术，为本文基于 3D Unet 头颈部 CT 图像器官分割算法提供理论基础。深度学习技术在医学图像上的应用分析了基于深度学习的医学图像分类、检测、分割和配准，并指出了其中的问题与前景。评价标准中主要介绍图像分割结果的评价标准与模型压缩的比较标准，为本文的算法对比提供量化指标。

3 基于 3D Unet 头颈部 CT 图像器官分割算法的研究

头颈部器官自动分割有着重要的临床意义。本文基于 3D Unet 对头颈部八个危及器官进行分割，分别是：脑干、左右眼睛、左右视神经、左右腮腺、下颌骨。本章提出的算法主要在 3D Unet 的基础上做了以下三点改进：1) 引入 Two Stage 训练与分割流程；2) 修改卷积层数、池化次数；3) 修改损失函数。实验结果表明，该算法整体提高了各个器官的分割精确度，且改善了因器官大小、体积不均而引起的分割精度差异性大的问题。下面主要介绍算法分析、算法的实现详情以及相关实验。

3.1 头颈部 CT 图像器官分割算法分析

放射治疗中，头颈部计算机断层扫描（CT）图像通常被用来指导计算放射剂量以及制定放疗计划，精准勾画出肿瘤和危及器官是准确计算放射剂量至关重要的一步。医生手动勾画器官的轮廓耗时且繁琐，研究危及器官自动分割算法可以减少医生的工作量、提高放疗效率。然而，由于以下三个主要因素的存在，自动分割头颈部 CT 图像中的危及器官仍是一项非常艰巨的挑战。第一，危及器官相对整张 CT 图像来说非常小；第二，不同器官在大小、体积、形状等方面差异性大，如：视神经很小，而下颌骨相对较大；第三，CT 图像中软组织对比度较差，有些器官与周围组织分界不明显，几乎看不到边界，如：左右视神经。

近年来，已经提出了很多技术和方法用于头颈部 CT 图像器官分割。这些方法主要分为：基于 Atlas 的分割算法，基于统计模型的分割算法和基于分类器的分割算法。详情见章节 1.2。基于 Atlas 的分割算法通常经过以下几个步骤：数据预处理、创建模板数据库、比对目标图像与模板图像的相似度、图像配准及融合。该方法较为繁琐且耗时，并且分割的结果会受到这些步骤中涉及的各种误差的影响；此外，基于 Atlas 的分割方法过度依赖模板图像和配准方法，如果模板图像选择不当，分割结果会变得很差。基于统计形状/外观模型的分割算法主要思想是将一个含有形状、外观等信息的模型匹配到目标图像上。由于包含内在的先验知识，基于模型的分割算法可以更好地抵抗局部图像扭曲和其他的干扰信息（如：噪声）。然而，基于模型的分割算法非常依赖器官的形状，如果器官受肿瘤的影响变化较大，分割出来的结果会非常差；此外，基于统计形状/外观模型的 CT 图像器官分割算法需要花费大量的时间和精力去标记样本点，通常一个 CT 图像需要标记 1500 个左右的样本点。基于分类器的分割算法非常依赖输入的特征，如果输入的特征不能准确表达待分割的器官，分割结果往往较差。综上所述，虽然这些算法可以实现头颈部危及器官的自动分割，但是存在分割精度不高、算法不稳定、分割流程复杂等问题。

近年来，卷积神经网络在各种医学图像分析任务（分类、检测、分割、配准等）中表现出了优异的性能。随着深度学习技术的不断发展，越来越多的深度学习技术应

用在头颈部 CT 图像器官分割中。基于深度学习的危及器官分割可以分为两类：1) 基于 CT 整张图像的多器官分割；2) 基于目标区域的单器官分割。详情见章节 1.2。基于 CT 整张图像的多器官分割算法全面利用多个待分割器官的标签信息和 CT 图像信息，训练神经网络得到一个能同时分割出所有危及器官的神经网络模型，可以一次性得到所有危及器官的分割结果。但由于危及器官只占整张图像的一小部分，且 CT 图像中危及器官与周围组织的对比度较低，多器官分割方法的分割精确度往往不高。基于目标区域的单器官分割方法是指根据不同器官的特定属性及该器官周围的区域信息，分别为每一个器官设计专属的神经网络分割模型，以达到该目标器官的最佳分割性能。然而，头颈部的危及器官有十多个，这意味着完成头颈部危及器官的自动分割需要设计十多个独立的模型，需要花费大量的时间和精力去训练模型。

此外，基于深度学习的头颈部 CT 图像器官分割还存在分割精确度差异性大的问题。对于与周围组织界限明显且较大的器官（如：下颌骨）可以得到较好的分割结果，而对于与周围组织分界不明显且较小的器官（如：视神经）往往得到的分割结果较差，未达到应用在临床的标准。因此，如何提升头颈部器官分割的整体精确度、提升小器官的分割精确度仍是业界的一大难题。

基于上述问题，本文提出基于 3D Unet 头颈部 CT 图像器官分割算法，该算法在原始 3D Unet 上做了以下三点改进：1) 针对头颈部 CT 图像软组织对比度不明显，器官在整张 CT 图像上占比小的问题，引入 Two Stage 训练与分割，第一阶段一次性分割出所有的器官，第二阶段提取第一阶段分割结果的 bounding box，再分别对不同的器官进行训练与分割，整体提高各个器官分割的精确度；2) 考虑到卷积深数过大会导致模型中参数过多引起过拟合、而卷积深数过小会导致模型中参数过少引起欠拟合，以及池化层数过多会导致丢失器官重要信息、而池化层数过少会导致模型“视野”较小分割能力差，修改了原始 3D Unet 网络模型中的卷积深度和池化次数，得到了一个适合于头颈部 CT 图像器官分割的 3D Unet；3) 使用 focal loss 损失函数替代交叉熵损失函数，弥补因器官大小、体积等差异大引起的分割精度差异大的问题。本文主要分割头颈部 CT 图像中的八个器官，分别是：脑干、左右眼睛、左右视神经、左右腮腺、下颌骨。分割效果如图 3-1，其中，图（a）、图（b）是不同方位看上去的效果。

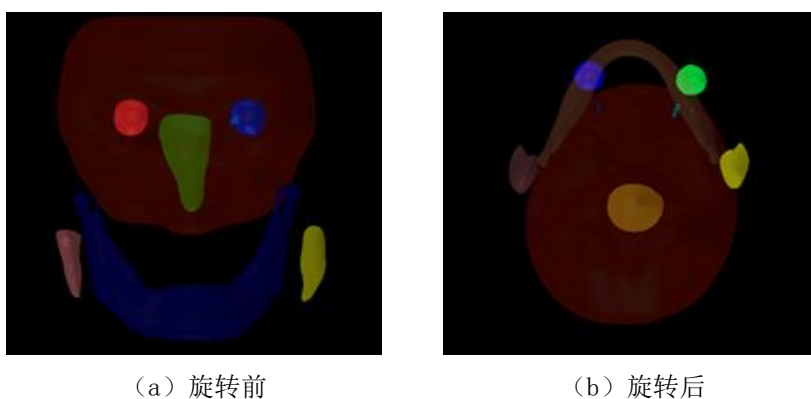


图 3-1 分割效果图

3.2 基于 3D Unet 头颈部 CT 图像器官分割算法的研究

基于 3D Unet 头颈部 CT 图像器官分割算法主要从卷积深度、池化层数和损失函数三个方面对原始 3D Unet 进行改进,得到一个适合头颈部 CT 图像器官分割的神经网络模型;此外,引入 Two Stage 训练与分割流程,将第一阶段的分割结果用于定位,提取出各个器官的 bounding box,第二阶段输入 bounding box 对每个器官进行更加精细的训练与分割。下面从数据预处理、Two Stage 训练与分割流程、神经网络整体结构三个方面对基于 3D Unet 头颈部 CT 图像器官分割算法进行描述。

3.2.1 数据预处理

一张头颈部 CT 图像通常由 100 个左右 dicom 文件组成。在处理 CT 图像前,首先需要从 dicom 文件中提取出 CT 值,将 CT 值表示成三维矩阵进行处理与分析。不同的 CT 设备所生成的 CT 图像在图像大小、像素间距、CT 值分布等方面存在差异,为了使不同 CT 设备产生的图像都能够使用基于 3D Unet 头颈部 CT 图像器官分割算法,本文对 CT 值进行了归一化、标准化的处理。头颈部 CT 图像相对较少,仅有 30 个训练数据,为了增强基于 3D Unet 头颈部 CT 图像器官分割算法的鲁棒性,进行了数据扩增操作。下面分别进行介绍。

1) 实验数据与环境

实验数据来自研二实习公司合作医院。其中训练集 30 个,验证集 10 个。训练集和测试集都包含 CT 图像(images)和医生在 CT 图像上勾画出的器官轮廓(labels)。实验 CT 数据的冠状面和矢状面如图 3-2 所示,图(a)是冠状面,图(b)是矢状面;灰色的是 CT 扫描所得的人体图像,红色、黄色、绿色等是医生在 CT 图像上标记出的各个危及器官。本文实验环境是:python3.5, Tensorflow1.6 框架,2 块 Nvidia GeForce 1080Ti 型号 GPU, Ubuntu16 的操作系统。




图 3-2 训练数据示意图

2) 数据分析

实验开始前,对待分割的八个器官(脑干、左右眼睛、下颌骨、左右腮腺、左右视神经)进行了数据分析,分别计算训练集中各个器官的 bounding box,记作: $A \times B \times C$ (其中 A 表示该器官在 CT 图像中占有的层数, B 表示该器官的最大长度, C 表示

该器官的最大宽度，单位：像素），结果如表 3-1 所示。其中，脑干、下颌骨和左右腮腺的层数较多，且每层的长宽面积也相对较大；左右眼睛的层数只有 7 层，相对较少；左右视神经的层数最少，只有 2 层，且每层的长宽面积也是最少的。总的来说，分割难点在于：1) 训练数据较少，仅有 30 个；2) 各器官大小严重不均，层数、面积和体积都不够均衡，层数最多是 28 层，最低是 2 层；体积最大约是 340000（下颌骨：28×93×130），最小约是 500（左右视神经：2×22×11）。

表 3-1 各个器官的 bounding box

器官	层数	长	宽
脑干	16	30	35
左右眼睛	7	25	25
下颌骨	28	93	130
左右视神经	2	22	11
左右腮腺	12	41	30

3) 像素值转化为 CT 值

实验中的每个数据都是由一组 dicom 文件组成的。解析 dicom 文件时，依据 ImagePositionPatient 属性将一层层 CT 图像堆叠起来，得到对应的三维 CT 图像。从 dicom 文件 PixelArray 属性中获取的是经过量化后的像素值，因此，需要将像素值转化为 CT 值，具体操作如式 3-1：

$$Hu = \text{pixelVal} \times \text{RescaleSlope} + \text{RescaleIntercep} \quad (3-1)$$

式中，pixelVal 指从 dicom 文件中获取的像素值，RescaleSlope 和 RescaleIntercep 是可以从 dicom 文件中获取的常量，Hu 指经过计算得到的 CT 值。

4) 归一化和标准化

各大设备厂商在 CT 设备的图像采集、存储等方面标准不同，因而不同医院的 CT 设备得到的 CT 图像也存在差异，主要体现在 CT 值的分布、像素间距、CT 层厚等的不一致。为了使最终得到的网络模型可以分割不同设备产生的 CT 图像，对 CT 图像进行归一化和标准化至关重要。

CT 值是人体组织密度的反应，单位是 Hounsfield Unit (Hu)，取值范围一般是 [-1000,1000]，空气的 CT 值最低，约为 -1000Hu，脂肪的 CT 值在 -90Hu 到 -70Hu 之间，软组织的 CT 值一般是在 30Hu 到 50Hu 之间，钙化和骨质的 CT 值较高，最高可达 1000Hu，金属物质的密度更高，如：嵌入人体的钢板，其 CT 值在 2000Hu 到 3000Hu 之间。在头颈部 CT 图像器官分割中，处理的对象主要是一些软组织，因此，取 CT 值范围在 -1000Hu 到 600Hu 之间，足够形成明显对比，且减少无关物质的影响。为了消除不同 CT 设备产生的图像 CT 值分布不同的影响，需要对数据进行归一化，具体操作如式 3-2：

$$\text{out} = \begin{cases} 0, (in + 1000) \leq 0 \\ 1, (in + 1000) \geq 1600 \\ in/1600, 0 < (in + 1000) < 1600 \end{cases} \quad (3-2)$$

式中， in 是指输入的 CT 值， out 表示归一化后的 CT 值。首先将 CT 值加上 1000 转化到 0 至 2000 之间；再把小于 0 的值置为 0，大于 1600 的值置为 1600；最后，除以最大值 1600 将 CT 值归一化到 0 至 1 之间。

此外，在训练数据中随机抽取 N 次对数据进行旋转、缩放微调，并求 N 个数据的均值与标准差，进行减均值除以标准差的操作，使数据服从均值为 0，方差为 1 的正太分布。具体操作如式 3-3、3-4、3-5：

$$\text{mean} = \frac{1}{N} \sum_0^N in_{mean} \quad (3-3)$$

$$\text{std} = \frac{1}{N} \sum_0^N in_{std} \quad (3-4)$$

$$\text{out} = (in - \text{mean})/\text{std} \quad (3-5)$$

式中， mean 指 N 张图像的均值， in_{mean} 指单张图像的均值； std 指 N 张图像的标准差， in_{std} 指单张图像的标准差； in 指输入的图像， out 指经过减均值除以标准差操作后符合正太分布的图像。本文中， N 的取值是 100。

训练集和测试集中的 CT 图像在像素间距（三维图像的 x 轴、 y 轴和 z 轴）存在不一致的现象，因此有必要进行标准化，使不同图像在三个维度的像素间距保持一致。如式 3-6、3-7：

$$r_{out} = r_{in} \times (r_s/R_s) \quad (3-6)$$

$$z_{out} = z_{in} \times (z_s/Z_s) \quad (3-7)$$

式中， r_{in} 指输入 CT 图像的长度， r_s 指输入 CT 图像在 r_{in} 轴上的像素间距， R_s 是人为设置的常量， r_{out} 指按照 R_s 标准化后 CT 图像的长度； z_{in} 指输入 CT 图像的层厚（相当于三维图像在 z 轴上的像素间距）， z_s 指输入 CT 图像的层厚， Z_s 是人为设置的常量， z_{out} 指按照 Z_s 标准化后 CT 图像的层厚。经过式 3-6 和式 3-7 的操作，得到标准化后的图像的长、宽和高（式中仅对长和层厚进行了计算，这是因为在 CT 图像中长和宽的值往往是相等的）。

5) 数据扩增

医学图像与自然界中的图像相比，数量级要小很多。本文实验中只有 30 个训练数据，而神经网络中有着数千万的参数，需要大量的训练数据。如果只拿 30 个数据用于神经网络的训练，很可能导致神经网络出现严重的欠拟合，因此需要对数据集进行扩增。人的高低、胖瘦或者是否存在肿瘤等因素会导致头颈部 CT 图像有所不同，而人的头型及器官在外形方面是非常类似的，仅在大小或者在头颈部中的相对位置存在细微的差别。本文采用轻微平移、旋转和缩放操作，对头颈部 CT 图像进行数据扩增，其中，平移操作设置的范围是 $[-8, +8]$ ，旋转角度设置的范围是 $[-5, +5]$ ，缩放比例设置的范围

是[0.9, 1.1]。图 3-3 是由一张 CT 图像及其标注经过三次变换后所生成的图像及标注，可以看到，经过平移、旋转和缩放操作所得到的 CT 图像与 CT 设备产生的 CT 图像差别不大。实验中，batch_size 设置为 1，即每次仅喂入神经网络一个 CT 数据，每一个数据在喂入神经网络之前，都进行平移、旋转和缩放的操作，最终，神经网络训练了多少次就使用了多少个不同但相似的 CT 数据。




图 3-3 数据扩增示意图

3.2.2 Two Stage 训练与分割流程

本文引入 Two Stage 训练与分割流程，基于 3D Unet 头颈部 CT 图像器官算法分为两个阶段：第一阶段的分割结果用于定位器官，第二阶段利用第一阶段的定位结果，为每个器官训练专属的网络模型，更加精细的分割器官。下面分别介绍 Two Stage 训练流程和 Two Stage 分割流程。

1) Two Stage 训练流程

Two Stage 训练流程第一阶段如图 3-4 所示。首先，将图像 (image) 和图像标注信息 (label) resize 到指定大小。通常，CT 图像的大小是 $512 \times 512 \times 100$ (其中，100 表示 slice 层数，每张 CT 图像 slice 层数不同，范围在 50 到 150 之间)。实验中处理 CT 图像使用的数据类型是 float32，计算下来一张 CT 图像约占 100M，再加上神经网络前向和方向传播所保存的副本，导致整个模型非常庞大。因此，对 CT 图像进行降采样处理，将 CT 图像的大小全部 resize 至 $208 \times 208 \times 72$ 。然后，输入 resized_image 和 resized_label 训练神经网络，得到一个可以同时分割出八个器官的网络模型 3D Unet1。运行 3D Unet1 输出 resized pre_label，进行后处理，将分割结果 resized pre_label 转变为 pre_label 映射回原图 (image) 中。




图 3-4 Two Stage 训练流程第一阶段

Two Stage 训练流程第二阶段如图 3-5 所示。首先，分别从原图（image）和原标注（label）中提取出各个器官的 bounding box 和 label。然后，将 image 和 label resize 到指定大小，输入神经网络，为每个器官单独训练分割模型，对模型输出的分割结果进行后处理，将分割结果映射到原图（image）中。

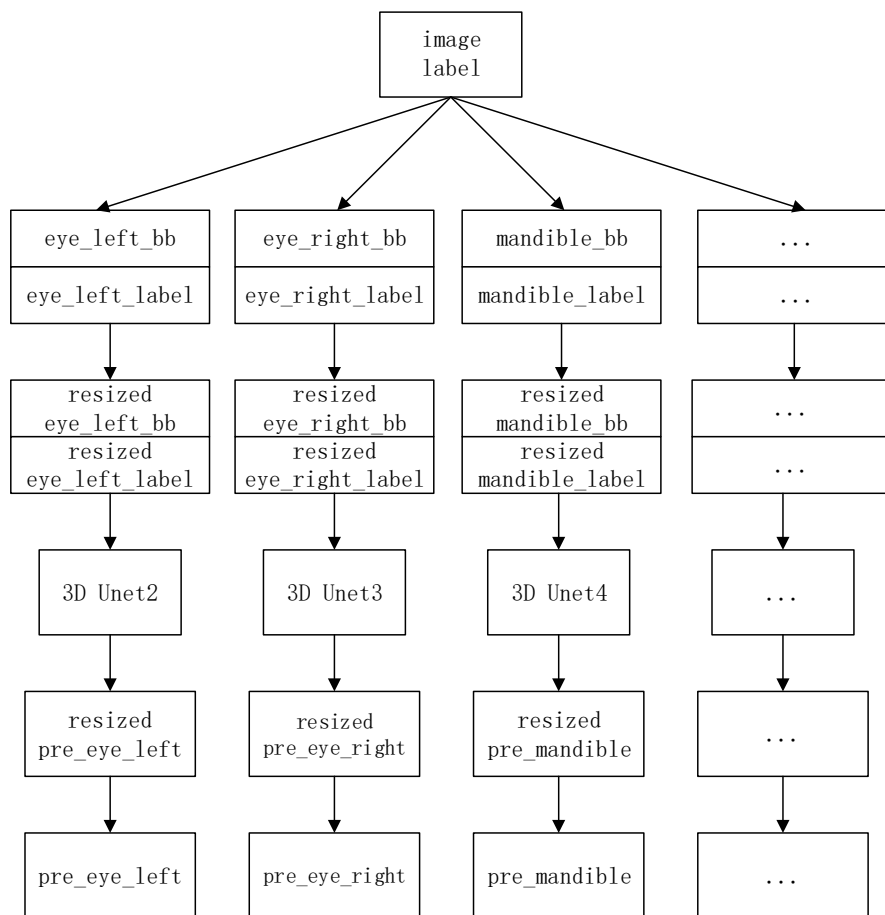


图 3-5 Two Stage 训练流程第二阶段

下颌骨训练流程第二阶段提取 bounding box 并 resize 如图 3-6 所示。左边红色框是从原图中提取出的 bounding box，浅绿色是下颌骨的标注信息；右边是对提取到的 bounding box 添加 padding 并 resize 到 $128 \times 128 \times 64$ 的图像。将 resize 之后的 bounding box 和 label 输入模型并训练，得到一个用于分割下颌骨的神经网络模型。




图 3-6 下颌骨训练流程第二阶段

原始 3D Unet 降采样 4 次，因此 resize 之后的图像应大于等于 $16 (2^4)$ ，结合表 3-1 中统计的各个器官真实 bounding box 的大小，本文设置了 Two Stage 训练流程中第二阶段 resize 之后的 bounding box 大小，如表 3-2 所示。考虑到眼睛和视神经相对较小且层数少，设置其大小为 $32 \times 32 \times 32$ ；脑干和腮腺比眼睛大又比下颌骨要小，设置其大小为 $64 \times 64 \times 64$ ；下颌骨相对于其他器官较大，设置其大小为 $128 \times 128 \times 64$ 。

表 3-2 各个器官 resize 之后的 bounding box

器官	层数	长	宽
脑干	64	64	64
左右眼睛	32	32	32
下颌骨	64	128	128
左右视神经	32	32	32
左右腮腺	64	64	64

2) Two Stage 分割流程

Two Stage 训练流程中，第一阶段和第二阶段是分开的，第二阶段输入的 bounding box 来自训练数据；Two Stage 分割流程中，第二阶段输入的 bounding box 来自第一阶段网络模型产生的分割结果。Two Stage 分割流程如图 3-7 所示。首先，将待分割的图像输入第一阶段训练好的网络模型，一次性得到八个器官的分割结果；然后，从分割结果中提取出各个器官的 bounding box，再将 bounding box 输入第二阶段每个器官各自的分割模型中，完成分割。

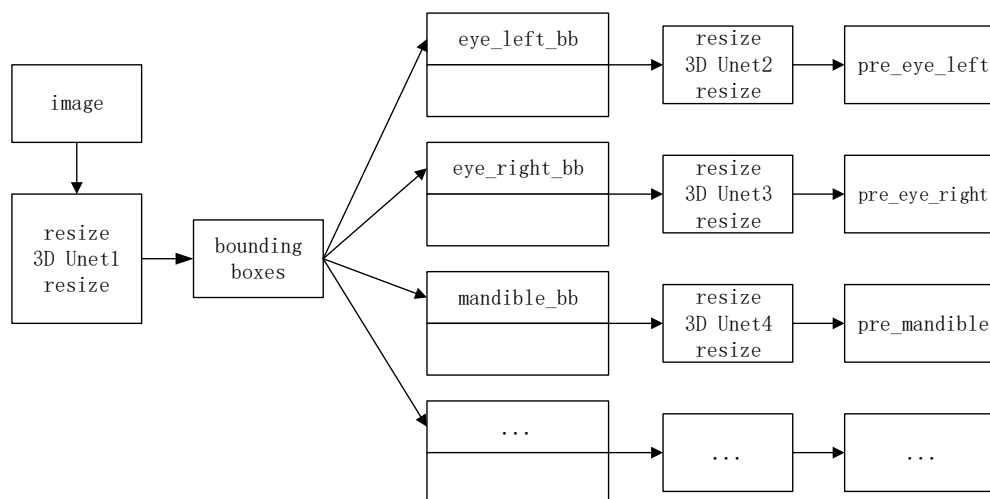


图 3-7 Two Stage 分割流程

3.2.3 神经网络整体结构

3D Unet 是由 2D Unet 扩展得到的 3D 全卷积网络模型。CT 图像是由多张二维图像堆叠而成的三维图像，使用二维卷积相当于默认这些图像是独立无关的，忽略了 CT 图像的层间信息，如：相邻图像之间的相似性。为了克服 2D 卷积在头颈部 CT 图像器官分割的弊端，有必要使用 3D 全卷积网络。3D Unet 能够利用 CT 数据的层间信息，

理论上可以得到更优的分割结果。

3D Unet 分为降采样和上采样两个阶段，通过把特征图上采样到跟原图大小一致实现像素级分类（图像分割）。直接使用原始 3D Unet 对头颈部 CT 图像器官进行分割得到的分割精度较差，考虑到池化次数、卷积深度会影响神经网络模型的分割精度，从池化次数和卷积深度对原始 3D Unet 进行改进，得到了一个适合头颈部 CT 图像器官分割的网络模型。

图 3-8 是本文改进后的 3D Unet 网络结构。第一阶段，输入 resized_images ($72 \times 208 \times 208 \times 1$) 和 resized_labels ($72 \times 208 \times 208 \times 9$)，经过两次卷积核大小为 $3 \times 3 \times 3$ 的卷积之后进行池化，该过程共执行三次，每次得到的特征图的 channels 是之前的两倍。特征图（默认输入图像是第一张特征图）的一系列变化为： $72 \times 208 \times 208 \times 1 \rightarrow 72 \times 208 \times 208 \times 24 \rightarrow 36 \times 104 \times 104 \times 48 \rightarrow 18 \times 52 \times 52 \times 96 \rightarrow 9 \times 26 \times 26 \times 192$ 。对最后一张特征图进行 dropout 操作，缓解过拟合问题。然后，对特征图进行反（转置）卷积，使特征图一步步恢复到之前的大小，特征图变化与之前相反；不同的是，为了融合浅层与深层特征图的信息，拼接转置卷积得到的特征图与之前相对应的特征图，然后对拼接后的特征图进行两次卷积，再继续进行反卷积。最终，输出的特征图的大小为 $72 \times 208 \times 208 \times 9$ 。第二阶段，一共训练了八个网络模型，分别分割不同的器官，输入 images 和 labels 的大小随着器官的不同而不同。以腮腺为例，输入的 images 大小为 $64 \times 64 \times 64 \times 1$ ，输入的 labels 大小为 $64 \times 64 \times 64 \times 2$ ，输出的预测结果大小为 $64 \times 64 \times 64 \times 2$ ，仅需进行器官与背景的像素级二分类。

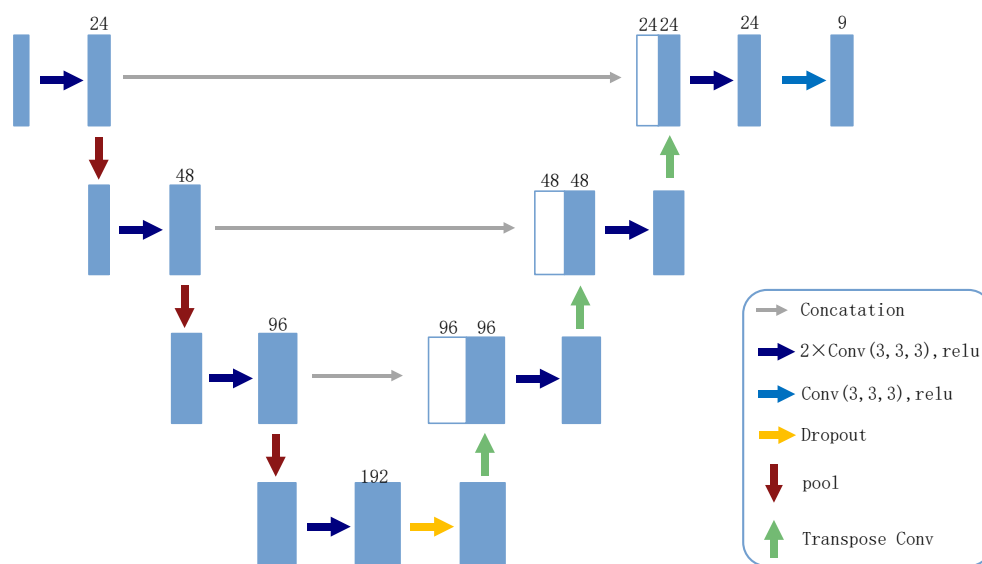


图 3-8 网络整体结构

表 3-3 是神经网络模型的具体实现细节，其中反斜杠“/”表示当前操作没有该参数。首先，对输入的头颈部 CT 图像进行了卷积与池化操作，然后，进行了特征图拼接、转置卷积上采样和卷积操作，将特征图恢复到输入图像的大小。其中，第一阶段网络模型的输入大小是 $208 \times 208 \times 72 \times 1$ ，输出大小是 $208 \times 208 \times 72 \times 9$ ，实现像素级九分类

(包括背景); 第二阶段网络模型的输入大小根据器官的不同而不同, 分割左视神经的小网络模型输出大小是 $32 \times 32 \times 32 \times 2$, 实现左视神经与背景的像素级二分类。

表 3-3 神经网络实现细节

操作	shape
input	208×208×72×1
conv3d_1	3×3×3×1×24
conv3d_2	3×3×3×24×24
max pooling1	/
conv3d_3	3×3×3×24×48
conv3d_4	3×3×3×48×48
max pooling2	/
conv3d_5	3×3×3×48×96
conv3d_6	3×3×3×96×96
max pooling3	/
conv3d_7	3×3×3×96×192
conv3d_8	3×3×3×192×192
dropout	/
transpose conv3d_1	2×2×2×192×96
concat1	/
conv3d_9	3×3×3×192×96
conv3d_10	3×3×3×96×96
transpose conv3d_2	2×2×2×96×48
concat2	/
conv3d_11	3×3×3×96×48
conv3d_12	3×3×3×48×48
transpose conv3d_3	2×2×2×48×24
concat3	/
conv3d_13	3×3×3×48×24
conv3d_14	3×3×3×24×24
conv3d_15 (output)	3×3×3×24×9

神经网络搭建好之后, 需要为网络模型设置一个优化目标 (损失函数), 训练神经网络模型使最终输出的结果与真实的 labels 接近, 从而利用模型输出的结果进行分割。

Dice 系数、交叉熵 (cross entropy, CE) 和 Focal loss 是医学图像分割中常用的损失函数。

交叉熵 (CE) 如式 3-8:

$$CE(pt) = -\log(pt), pt = \begin{cases} p, & \text{if } y = 1 \\ 1 - p, & \text{otherwise} \end{cases} \quad (3-8)$$

式中, p 是指预测正确的概率, $1-p$ 是指预测错误的概率, 取 $\log(pt)$ 的负数得到交叉熵。交叉熵分别计算每个种类, 采取平均值作为结果, 不能解决类别不平衡的问题。

Dice 系数 (dice) 如式 3-9:

$$dice = \frac{2|A \cap B|}{|A| + |B|} \quad (3-9)$$

式中, A 是指预测的分割结果, B 是指真实的分割结果, 取预测结果与真实值交集的 2 倍, 除以预测结果和人工标记信息的和, 得到 Dice 系数。Dice 系数本质上是衡量两个样本的重叠程度, 也是一种评估指标。Dice 系数也是分别计算每个种类, 采取平均值作为结果, 不能解决类别不平衡的问题。

Focal loss (FL) 如式 3-10:

$$FL(pt) = -\alpha_t(1 - pt)^\gamma \log(pt), pt = \begin{cases} p, & \text{if } y = 1 \\ 1 - p, & \text{otherwise} \end{cases} \quad (3-10)$$

式中, α_t 和 γ 分别是平衡因子和调节因子。Focal loss 在 CE 的基础上添加平衡因子及调节因子, 解决了类别不平衡的问题。

本文对比了交叉熵、dice loss 和 focal loss 做为优化目标时的分割结果, 选择使用 Focal loss 作为优化目标 (损失函数)。训练神经网络时, 本文使用的优化器是 Adam, learning rate 设置为 0.001, 一共训练了 6000 步。

3.3 实验结果与分析

3.3.1 池化次数对分割精度的影响

在头颈部 CT 图像器官分割中, 器官占整张图像的比例相对较小, 池化会逐步丢失可描绘器官的重要信息。考虑到池化次数过多, 会丢失信息; 而池化次数过少又会影响到整个网络的“视野”, 为了得到最佳的池化次数, 实验对比了 2 次池化、3 次池化与 4 次池化模型的结果。(此时, 初始卷积核深度是 24, 损失函数是交叉熵。)

实验结果如表 3-4 所示, 可以看到 2 次池化模型的分割精度比 3 次池化模型的分割精度低很多, 约低 14%, 且 2 次池化模型没能分割出左右视神经; 4 次池化模型的分割精度比 3 次池化模型略高一点, 约高 0.4%。4 次池化模型并没有大幅度地提升分割精确度, 考虑到 4 次池化模型比 3 次池化模型占用更多内存以及花费更多时间训练、分割, 本文最终确定对网络进行 3 次池化。

表 3-4 不同池化次数的分割结果 (dice)

器官	Pool2	Pool3	Pool4
脑干	0.524	0.645	0.647
左眼睛	0.780	0.843	0.849

表 3-4 (续)

器官	Pool2	Pool3	Pool4
右眼睛	0.768	0.832	0.836
下颌骨	0.862	0.878	0.882
左视神经	0	0.325	0.331
右视神经	0	0.317	0.320
左腮腺	0.633	0.731	0.736
右腮腺	0.608	0.706	0.712
Average	0.522	0.660	0.664

3.3.2 卷积深度对分割精度的影响

卷积深度决定经过一次卷积得到的特征图的数目。卷积深度过少，提取的特征相对较少，可能漏掉某些重要信息，导致网络模型欠拟合；而卷积核深度过多，提取的特征相对较多，可能把噪音当做图像本身的特征，导致网络模型过拟合。为了得到最佳的卷积核深度，本文对初始卷积核深度为 12，24，36 的网络模型进行实验对比。需要注意的是，这里的深度是指第一次卷积时的卷积核深度，此后，每进行一次池化，卷积核的深度翻倍一次。（此时，池化层数是 3 层，损失函数是交叉熵。）

由于本文直接处理的三维数据，当卷积核深度设置为 36 时，网络模型占用内存过多，在 2 块 Nvidia GeForce 1080Ti 型号 GPU 上无法运行，故实验结果中不含卷积核数量为 36 的一项。图 3-9 是网络模型在最后 500（5500 至 6000）步时，loss 下降对比，其中，kernels-24 指初始卷积深度为 24，kernels-12 指初始卷积深度为 12。当初始卷积深度为 24 时，loss 较低，在 0.001 上下浮动；当初始卷积深度为 12 时，loss 较高，在 0.004 上下浮动，且上下波动较大。




图 3-9 不同卷积深度 loss 值

表 3-5 是初始卷积深度为 12 和 24 时的分割结果对比。初始卷积深度为 12 时，分割能力较差，仅能分割出脑干和下颌骨，且脑干的精确度比初始卷积核深度为 24 时低

10%。下颌骨的分割精度差距相对较小（4%），这是因为下颌骨相对于其他器官较大、与周围组织分界较明显。结合图 3-9 和表 3-5 推论出，当初始卷积核深度为 12 时，网络模型太小，未能学习到足够的特征，存在欠拟合现象。

表 3-5 不同初始通道数的分割结果（dice）

器官	12	24
脑干	0.541	0.645
左眼睛	0	0.843
右眼睛	0	0.832
下颌骨	0.835	0.878
左视神经	0	0.325
右视神经	0	0.317
左腮腺	0	0.731
右腮腺	0	0.706

3.3.3 损失函数对分割精度的影响

Dice 系数、交叉熵、Focal loss 是医学图像分割中常用的损失函数。Dice 系数和交叉熵都是分别对每个类别进行计算，取平均值作为结果，无法解决类别不平衡的问题；Focal loss 在交叉熵的基础上，添加了平衡因子和调节因子，理论上可以解决类别不平衡的问题。为了验证 Focal loss 可以解决类别不平衡问题、提高小器官（如：视神经）的分割精确度，本文设计了使用不同损失函数的对比实验。

表 3-6 是使用不同损失函数得到的分割结果。整体看来，使用 dice 系数比使用交叉熵精确度低 3%，使用 focal loss 比使用交叉熵精确度高 1%。左视神经的分割精确度在 focal loss 模型中比在交叉熵模型中高 1.3%，分割精度提升相对较高。本文最终使用 focal loss 作为损失函数。

表 3-6 不同损失函数分割结果对比（dice）

器官	dice	cross entropy	focal loss
脑干	0.617	0.645	0.658
左眼睛	0.803	0.843	0.851
右眼睛	0.795	0.832	0.840
下颌骨	0.871	0.878	0.883
左视神经	0.287	0.325	0.338
右视神经	0.276	0.317	0.327
左腮腺	0.702	0.731	0.743
右腮腺	0.695	0.706	0.715
Average	0.631	0.660	0.670

3.3.4 Two Stage 流程对分割精度的影响

Two stage 训练与分割流程详情见章节 3.2.2。为了提高器官的分割精确度，尤其是提高小器官的分割精确度，本文采用先定位再分割的方法，与其他方法不同的是：第一阶段用于定位的神经网络是一个分割模型，第二阶段从分割结果中提取各个器官的位置 (bounding box)，再进行器官与背景的二分类。此时，池化次数是 3 次，初始卷积深度是 24，第一阶段使用的损失函数是 focal loss，第二阶段使用的损失函数是带有比例项的交叉熵。

实验中从第一阶段分割过程中随机抽取了部分特征图，如图 3-10 所示，第一行到第三行是降采样阶段特征图，第四行到第六行是上采样阶段特征图。可以看到第一阶段神经网络提取的是所有器官的整体信息，特征图中器官所占的比例非常小，而 CT 设备这一噪声占的比例相对较大。




图 3-10 第一阶段特征图

实验中从第二阶段分割左眼睛的过程中随机抽取了部分特征图，如图 3-11 所示，

第一行到第三行是降采样阶段特征图，第四行到第六行是上采样阶段特征图。图 3-10 第一阶段的特征图中器官只占很小的一部分，且每张特征图上都含有“CT 设备”这一噪声，由于是同时分割多个器官，特征图中激活的信息较多；图 3-11 第二阶段分割眼睛的特征图中器官所占比例较大，特征图上几乎没有噪声，由于仅进行眼睛与背景的像素级二分类，特征图中激活的信息较为专一，可以更加精细分割地分割器官。




图 3-11 第二阶段分割左眼睛特征图

本章对比了第一阶段与第二阶段的分割结果，如表 3-7。由于第二阶段为每个器官训练专属的分割模型且输入神经网络模型的是仅包含器官的图像，神经网络在提取特征时更加“专一”，分割的精度也就更高。第二阶段相比于第一阶段分割精确度总体提升了 6%。由于神经网络提取特征的能力是有上限的，第一阶段分割精度较好的器官在第一阶段时提取的特征已经足够优秀，在第二阶段提取特征的能力提升不大，导致分割精度提升不大，如：下颌骨的分割精确度仅提升 2%；而对于第一阶段分割精度较差的器官而言，其特征提取存在较大的提升空间，在第二阶段可以专注提取更多有用的特征，因而分割精度提升较大，如：左右视神经分割精度提升约 9%。

表 3-7 第一阶段与第二阶段的分割结果对比 (dice)

器官	第一阶段	第二阶段
脑干	0.658	0.747
左眼睛	0.851	0.897
右眼睛	0.840	0.881
下颌骨	0.883	0.906
左视神经	0.338	0.422
右视神经	0.327	0.414
左腮腺	0.743	0.794
右腮腺	0.715	0.776
Average	0.670	0.730

图 3-12 是第一阶段和第二阶段的部分器官的分割效果图,从上到下分别是:脑干、左眼睛、右眼睛、下颌骨、左视神经、右视神经、左腮腺、右腮腺;从左到右分别是:原图、手工标注信息、第一阶段的分割结果、第二阶段的分割结果。从图中可知,第一阶段的分割结果比较粗略,第二阶段的分割结果更为精细也更接近真实的标注信息。实验结果表明,采用 Two Stage 方法可以显著提升器官的分割精确度,尤其提升小器官的分割精确度。




图 3-12 第一阶段和第二阶段部分器官分割效果图 (a)




图 3-12 第一阶段和第二阶段部分器官分割效果图（b）

3.3.5 算法对比与应用

为了将本文算法与其他头颈部 CT 图像分割算法进行对比,在本文使用的数据集上运行了 MICCAI 头颈部 CT 图像器官分割挑战赛上较为优秀的算法 AnatomyNet, 分割结果如表 3-8 所示。实验结果表明: 在本文数据集上, 基于 3D Unet 头颈部 CT 图像器官分割算法优于 AnatomyNet 算法, 可以取得更好的分割结果。

表 3-8 不同分割算法在本文数据集上的对比（dice）

器官	本文算法	AnatomyNet
脑干	0.747	0.751
左眼睛	0.897	0.884
右眼睛	0.881	0.875
下颌骨	0.906	0.910
左视神经	0.422	0.406
右视神经	0.414	0.398
左腮腺	0.794	0.786
右腮腺	0.776	0.752
平均值	0.730	0.721

为了证明本章算法的普遍适用性，在 MICCAI 2015 头颈部 CT 图像数据集上训练并测试了本章算法，并与其他算法的分割结果进行了对比，如表 3-9 所示。由于 MICCAI 的数据集经过处理，相比于本文测试集，在 MICCAI 测试集上运行各算法均得到更高的分割结果。MICCAI 数据集中没有眼睛的标注信息，所以表 3-9 中没有对眼睛的分割精度进行对比；此外，很多算法仅对部分器官进行了分割，表中 N 表示未对该器官进行分割。实验结果表明：相比其他算法，本文算法可以取得更好的分割结果。分割小器官（左、右视神经）的精确度约高于其他算法 2%。

表 3-9 不同分割算法在 MICCAI 数据集上的对比（dice）

器官	本文算法	AnatomyNet	Fritscher et al	Ren et al
脑干	0.857	0.865	N	N
左眼睛	N	N	N	N
右眼睛	N	N	N	N
下颌骨	0.930	0.925	N	N
左视神经	0.741	0.721	N	0.720
右视神经	0.733	0.710	N	0.700
左腮腺	0.890	0.881	0.810	N
右腮腺	0.882	0.874	0.810	N

表 3-10 是将基于 3D Unet 头颈部 CT 图像器官分割算法应用在胸腔部、腹部和盆腔部 CT 图像危及器官分割中得到的结果。该算法目前已经应用在 70 家医院，医生仅需微调自动勾画的结果，便可应用。

表 3-10 不同部位器官分割（dice）

头颈部		胸腔部		腹部		盆腔部	
器官	dice	器官	dice	器官	dice	器官	dice
脑干	0.747	脊髓	0.823	左肾	0.841	膀胱	0.705
左眼睛	0.897	左肺	0.964	右肾	0.905	左股骨头	0.745
右眼睛	0.881	右肺	0.970	肝	0.920	右股骨头	0.688
下颌骨	0.906	心脏	0.828	脊髓	0.804	小肠	0.614
左视神经	0.422	食管	0.656			直肠	0.650
右视神经	0.414					脊髓	0.671
左腮腺	0.794						
右腮腺	0.776						

图 3-13 是本章算法应用在盆腔部 CT 图像危及器官分割的结果，其中，图（a）是小肠，图（b）是膀胱、左右股骨头和直肠。相比头颈部，盆腔部器官变化较大，如小肠、膀胱，但本章算法仍能取得很好的分割结果。




图 3-13 盆腔部器官分割结果

3.4 本章小结

本章针对头颈部 CT 图像器官分割问题提出了基于 3D Unet 的分割算法。从池化次数、卷积深度和损失函数三个方面对 3D Unet 网络进行了改进，得到了一个适合头颈部 CT 图像器官分割的算法模型。同时，引入 Two Stage 训练与分割流程，提取第一阶段分割结果的 bounding box 用来定位各个器官，第二阶段更加精细地分割器官，显著地提升了各个器官的分割精确度。最后，在本文数据集和 MICCAI 公开数据集上对比了本章算法和其他分割算法，实验结果表明：本章算法相比其他算法有更好的分割效果。

4 基于模型压缩的 3D Unet 头颈部 CT 图像器官分割算法的研究

基于 3D Unet 头颈部 CT 图像器官分割算法能够很好地分割器官，但由于是直接处理三维图像，模型的体积非常庞大，仅能在计算能力很强的设备上部署，此外，运行模型进行器官分割时占用的内存非常大也非常耗时。针对这些问题，本章使用模型压缩算法对基于 3D Unet 头颈部 CT 图像器官分割算法模型进行压缩。最终，实验结果表明，压缩后的算法不仅大大降低了模型的体积，提升了模型的计算效率，而且没有降低模型的分割精度。下面主要介绍模型压缩算法分析、算法的具体实现以及相关测试。

4.1 基于 3D Unet 头颈部 CT 图像器官分割算法分析

基于 3D Unet 头颈部 CT 图像器官分割算法分为两个阶段，第一阶段输入图像大小为 $208 \times 208 \times 72$ ，表 4-1 中统计了运行第一阶段神经网络模型时卷积、池化、反卷积以及所有特征图的内存占用情况，运行时约有 3G 的数据参与计算；第二阶段输入图像大小依据不同的器官而不同，详情见表 3-2，其中，下颌骨分割模型输入图像大小为 $128 \times 128 \times 64$ ，运行时约有 1G 的数据参与计算，脑干、眼睛、腮腺分割模型输入图像大小为 $64 \times 64 \times 64$ ，运行时约有 250M 的数据参与计算，视神经分割模型输入图像大小为 $32 \times 32 \times 32$ ，运行时参与计算的数据仅有 30M。此外，经统计，第一阶段运行时约花费 30s，第二阶段分割一个器官平均约花费 2s，八个器官约 16s，即基于 3D Unet 头颈部 CT 图像器官分割算法分割出八个器官约花费 46s。综上，基于 3D Unet 头颈部 CT 图像器官分割算法虽然在分割精度上达到应用在医院的水准，但在内存占用和分割时间方面仍需要提高，因此有必要对模型进行压缩，减少模型的内存占用和分割时间。

表 4-1 conv 和 feature map 内存占用

操作	shape	size
input	$208 \times 208 \times 72 \times 1$	12MB
conv3d_1	$3 \times 3 \times 3 \times 1 \times 24$	2KB
feature map1	$208 \times 208 \times 72 \times 24$	288MB
conv3d_2	$3 \times 3 \times 3 \times 24 \times 24$	48KB
feature map2	$208 \times 208 \times 72 \times 24$	288MB
max pooling1	/	/
feature map3	$104 \times 104 \times 36 \times 24$	37MB
conv3d_3	$3 \times 3 \times 3 \times 24 \times 48$	96KB
feature map4	$104 \times 104 \times 36 \times 48$	74MB
conv3d_4	$3 \times 3 \times 3 \times 48 \times 48$	192KB
feature map5	$104 \times 104 \times 36 \times 48$	74MB

表 4-1 (续)

操作	shape	size
max pooling2	/	/
feature map6	52×52×18×48	9MB
conv3d_5	3×3×3×48×96	384KB
feature map7	52×52×18×96	18MB
conv3d_6	3×3×3×96×96	768KB
feature map8	52×52×18×96	18MB
max pooling3	/	/
feature map9	26×26×9×96	2MB
conv3d_7	3×3×3×96×192	1MB
feature map10	26×26×9×192	4MB
conv3d_8	3×3×3×192×192	2MB
feature map11	26×26×9×192	4MB
dropout	/	/
feature map12	26×26×9×192	4MB
transpose conv3d_1	2×2×2×192×96	0.5M
feature map13	52×52×18×96	16MB
concat1	/	/
feature map14	52×52×18×192	32MB
conv3d_9	3×3×3×192×96	1MB
feature map15	52×52×18×96	16MB
conv3d_10	3×3×3×96×96	0.5MB
feature map16	52×52×18×96	16MB
transpose conv3d_2	2×2×2×96×48	147KB
feature map17	104×104×36×48	74MB
concat2	/	/
feature map18	104×104×36×96	148MB
conv3d_11	3×3×3×96×48	250KB
feature map19	104×104×36×48	74MB
conv3d_12	3×3×3×48×48	125KB
feature map20	104×104×36×48	74MB
transpose conv3d_3	2×2×2×48×24	36KB
feature map21	208×208×72×24	288MB

表 4-1 (续)

操作	shape	size
concat3	/	/
feature map22	208×208×72×48	576MB
conv3d_13	3×3×3×48×24	64KB
feature map23	208×208×72×24	288MB
conv3d_14	3×3×3×24×24	32KB
feature map24	208×208×72×24	288MB
conv3d_15	3×3×3×24×9	23KB
feature map25	208×208×72×9	112MB
sum	/	≈3G

减少神经网络模型的内存占用、提高模型的运行速度，高效运行神经网络是一个备受关注的话题。目前，解决这一难题主要有两种思路：1) 从硬件角度考虑，针对神经网络计算和访存的特点，设计具有高能效比的专用加速器，采用异构的计算方式来实现神经网络的部署；2) 从算法角度考虑，研究模型压缩方法，最大化降低模型的存储和计算需求。相比于从硬件角度出发，模型轻量化方法可以在不更换硬件平台的情况下提升运行的能耗比。为轻量化模型设计专用的硬件加速算法可以达到更好的效果。

从基于 3D Unet 头颈部 CT 图像器官分割算法 Two Stage 分割流程考虑：1) 第一阶段运行模型时占用 3G 内存，第二阶段运行模型时占用的内存不足 1G；2) 运行第一阶段模型约花费 30s，运行第二阶段分割出八个器官需要 16s，平均分割一个器官约 2s；3) 第一阶段模型主要目的是用于定位器官，第二阶段会先将第一阶段的定位结果进行修正（扩大 bounding box）再进行器官的精细分割，即使第一阶段定位结果稍有偏差也不会对第二阶段造成很大的影响。因此，本文对基于 3D Unet 头颈部 CT 图像器官分割算法第一阶段网络模型进行压缩，如图 4-1 所示，旨在不降低器官分割精确度的情况下，减小模型运行时的内存占用，减少分割器官时所花费的时间。

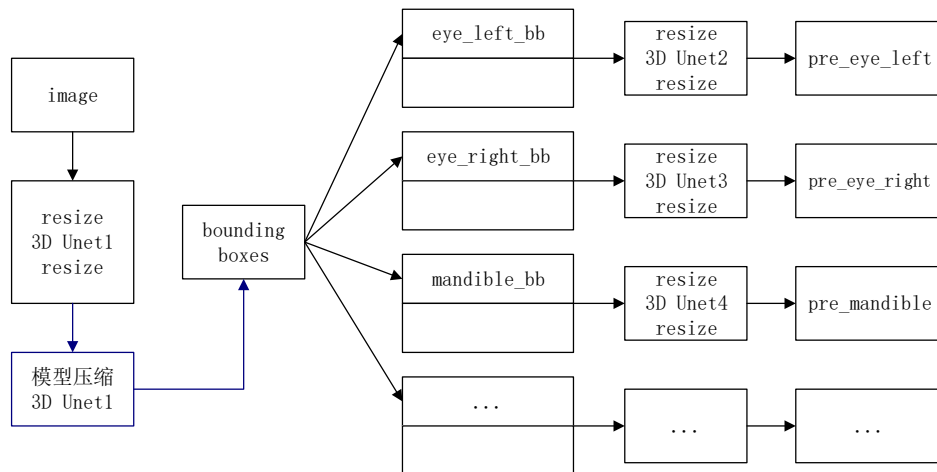


图 4-1 第一阶段模型压缩

4.2 基于模型压缩的 3D Unet 头颈部 CT 图像器官分割算法的研究

本章主要对基于 3D Unet 头颈部 CT 图像器官分割算法中第一阶段用于定位的网络模型进行压缩,如图 4-1 所示。对神经网络的压缩主要分为以下两个方面:1)为了在软件层面减少模型运行时内存占用和分割时间,对模型进行通道剪枝;2)为了配合硬件存储和加速工作,首先,对通道剪枝后的模型进行阈值剪枝,增加模型的稀疏性;然后,对阈值剪枝后的模型进行权值量化,减少权值存储时占用的位数,为硬件加速提供条件。下面按照对 3D Unet 模型压缩的顺序,分别介绍通道剪枝、阈值剪枝和多值化量化的实现。

4.2.1 基于通道剪枝的 3D Unet 算法

神经网络属于参数冗余模型,剪枝主要删除不重要的参数或结构,从而达到降低网络模型参数量的目的。由于删除的都是对神经网络影响很微小的参数或结构,剪枝算法能够在几乎无损精度的情况下实现较高的压缩比。

为了说明通道剪枝,这里首先介绍卷积过程。图 4-2 中是两次卷积过程,第 1 列是输入图像,大小为 $5 \times 5 \times 3$ (5 指图像的长和宽,3 指图像的通道数);第 2 列是 4 个 $3 \times 3 \times 3$ 的卷积核(卷积核的输入通道数与图像的通道数一致);第 3 列是每个卷积核卷积得到的特征图,因为一共有 4 个卷积核,所以得到 4 个特征图;第 4 列是对特征图堆叠得到的卷积结果,大小为 $5 \times 5 \times 4$;第 5 列是 3 个 $3 \times 3 \times 4$ 的卷积核(卷积核的输入通道数与图像的通道数一致);第 6 列是每个卷积核卷积所得到的特征图,因为一共有 3 个卷积核,所以得到 3 个特征图;第 7 列是对特征图堆叠得到的卷积结果,大小为 $5 \times 5 \times 3$ 。

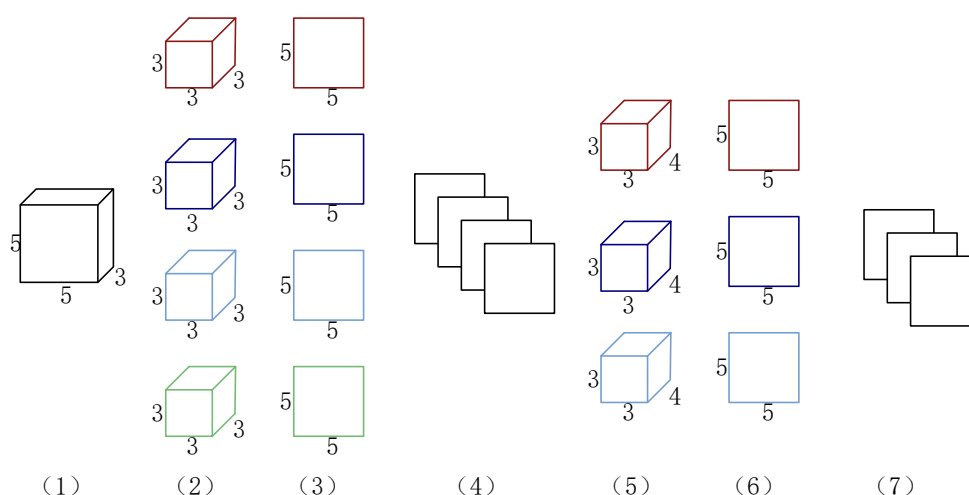


图 4-2 卷积示意图

在图 4-2 的基础上进行通道剪枝,如图 4-3。首先,计算第 2 列卷积核权重的绝对值之和,由于一共是 4 个卷积核所以得到 4 个值;然后,对绝对值之和进行从小到大排序,假设剪枝率为 0.5,则剪去较小的 2 (4×0.5) 个卷积核,图中是剪去了第 2 和第 4 个卷积核,此时,第 4 列卷积结果的大小变成了 $5 \times 5 \times 2$ 。通道剪枝改变了卷积的

结果，因此对一层卷积剪枝后会对接下来的卷积造成影响。对于第 5 列，输入图像的大小变成了 $5 \times 5 \times 2$ ，所以卷积核的大小变成了 $3 \times 3 \times 2$ ，不同于图 4-2 中第 5 列卷积核的大小 ($3 \times 3 \times 4$)。对比图 4-2，剪枝后神经网络结构上发生了变化，由于减少了卷积核和对应的特征图，模型的体积会变小、运算速度会加快。




图 4-3 通道剪枝示意图

运行 3D Unet 头颈部 CT 图像器官分割算法，会生成很多中间特征图。图 4-4 是随机抽取的某层卷积得到的特征图。




图 4-4 某一层特征图

图 4-4 中，第 2 列、第 3 列提取到的特征主要是 CT 设备，这属于噪声，会影响分割精度；第 1 列特征图中含有少部分 CT 设备特征，同样会影响分割精度；第 4 列特征图中仅含有器官及头部特征，是期望提取的特征。其次，特征图之间相似度非常高，如第 2 列、第 3 列。综上，虽然在第三章中设置了合适的卷积深度，但得到的特征图仍然是非常冗余的。

特征图数量的多少是由卷积核输出通道数决定的。考虑到以下两点：1) 特征图越多，模型运行时占用内存越大，运行越耗时；2) 很多特征图是冗余的，图 4-4 中很多特征图包含有 CT 设备这一噪声，对分割结果无益。对基于 3D Unet 头颈部 CT 图像器官分割算法第一阶段网络模型进行通道剪枝，旨在减少输出特征图的数量，使神经网络在特征提取时更加专注器官本身。本章直接在第三章训练好的模型上进行通道剪枝，如图 4-5 所示。

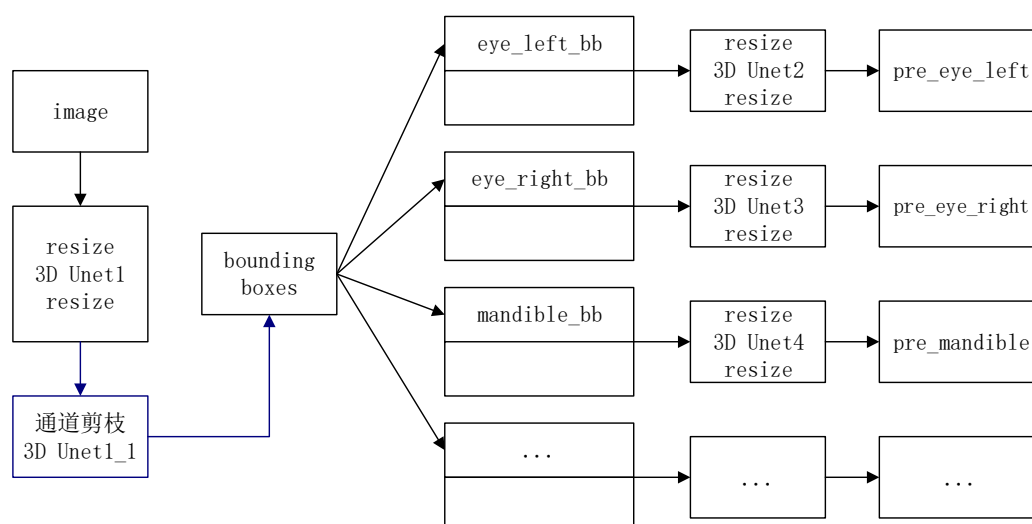


图 4-5 通道剪枝

基于通道剪枝算法的伪代码如下，主要分为五步：1) 设置初始剪枝率和终止剪枝率；2) 遍历待剪枝神经网络的每一层，对每一个卷积核计算权重绝对值之和并排序，依据剪枝率将最小的某些卷积核置为零，假设：某一层卷积核为 $3 \times 3 \times 3 \times 48 \times 96$ ，剪枝率为 15%；计算各卷积核权重绝对值之和得到 96 个数，由于剪枝率是 15%，将绝对值之和较小的 14 个卷积核中的权值全部置为 0 ($96 \times 0.15 = 14.4$ ，这里舍弃小数点后面的数)；3) 对剪枝后的神经网络进行再训练，再训练时置为零的卷积核不再参与反向传播，本文设置再训练的次数为 2000 次；4) 增大剪枝率，对上一轮剪枝及再训练后的模型再次剪枝，直到达到终止剪枝率；5) 将权值均为 0 的卷积核及对应的 feature map 从网络模型中移除，真正意义上实现结构化剪枝。文中计算并对比了不同剪枝率下模型的大小与精度，详情见实验 4.3.1 部分，最终从剪枝后模型的大小与精度两个方面考虑，选定合适的剪枝率。

算法 4-1 通道迭代剪枝算法

输入: $\{w_k, 0 \leq k \leq C\}$: 待剪枝的模型，共有 C 层; **start:** 初始剪枝率，取值范围是 $[0,1]$ ，文中 $\text{start}=0.05$;
end: 终止剪枝率，取值范围是 $[\text{start},1]$ ，文中 $\text{end}=0.25$ 。

输出: $\{w_k, 0 \leq k \leq C\}$: 剪枝后的模型

Repeat

for $k = 0, 1, \dots, C$ do

 计算 w_k 中卷积核的绝对值之和，并排序

 将 w_k 中卷积核绝对值最小的 start 部分置为零

算法 4-1 (续)

```

end for
Repeat
    前向传播
    反向传播 (为置为 0 的卷积核设置掩膜, 这些卷积核不参与反向传播)
Until 达到最大迭代次数
start ← start + 0.05 增大剪枝率, 在上一次剪枝的基础上继续剪枝
Until start ≥ end 持续剪枝与再训练, 直到剪枝率达到 end
将权值均为零的卷积核从结构上剪掉

```

4.2.2 基于阈值剪枝的 3D Unet 算法

阈值剪枝旨在增加模型的稀疏性, 配合硬件减少存储和加速相关工作。在图 4-2 的基础上进行阈值剪枝, 如图 4-6 所示。设置一个阈值, 遍历所有的卷积核, 将小于阈值的权重设置为 0 (图中的深色部分表示减去的元素), 大于阈值的权重不变。与图 4-2 相比, 阈值剪枝增加了模型的稀疏度, 但没有改变神经网络的结构, 特征图的维度也不会改变; 与图 4-3 相比, 阈值剪枝作用于神经网络中卷积核的权值, 不存在影响下一次卷积的情况。阈值剪枝不会改变初始神经网络的结构, 因此, 阈值剪枝又称为非结构化剪枝。

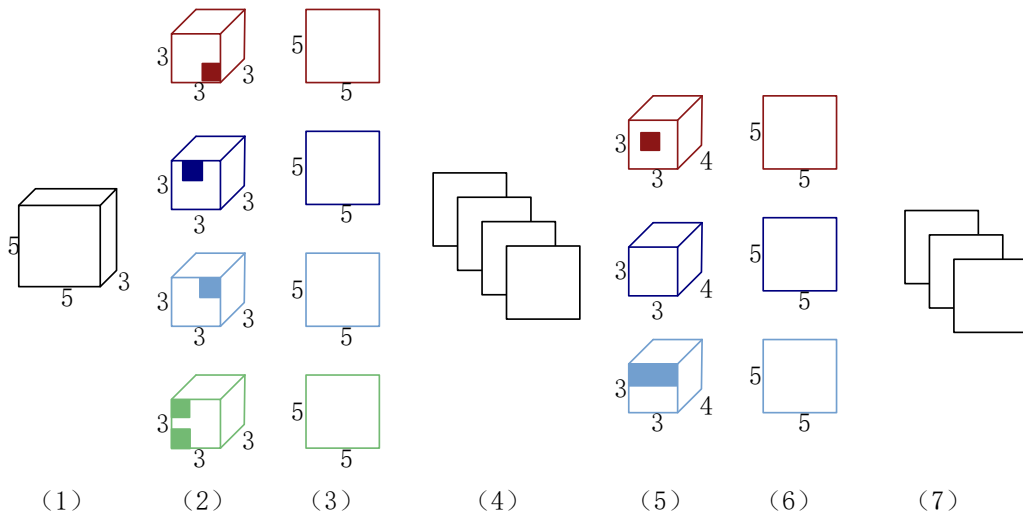


图 4-6 阈值剪枝示意图

通道剪枝后, 第一阶段网络模型运行时占用约 2G 内存, 运行时间是 20s, 相比于第二阶段网络模型的内存占用以及运行时间仍然非常高。图 4-7 是从通道剪枝后的模型中随机抽取的八个卷积核所生成的权值分布图, 其中, 横坐标表示权值的大小, 纵坐标表示对应的数量。分析权值分布图可知: 卷积核的权值较小, 大都分布在 -0.4 到 0.4 之间, 接近 0 的权值数量非常多, 且有关于 0 对称的趋势。由于稀疏化 (0 越多, 稀疏性越高) 模型能够有效减少硬件平台所需的存储空间, 减少访问存储的次数, 还可以通过跳零等方式减少计算量, 降低模型的运行时间。本章对剪枝后的模型进行阈值剪枝, 增加模型的稀疏性, 进而配合硬件减少内存、加速计算。

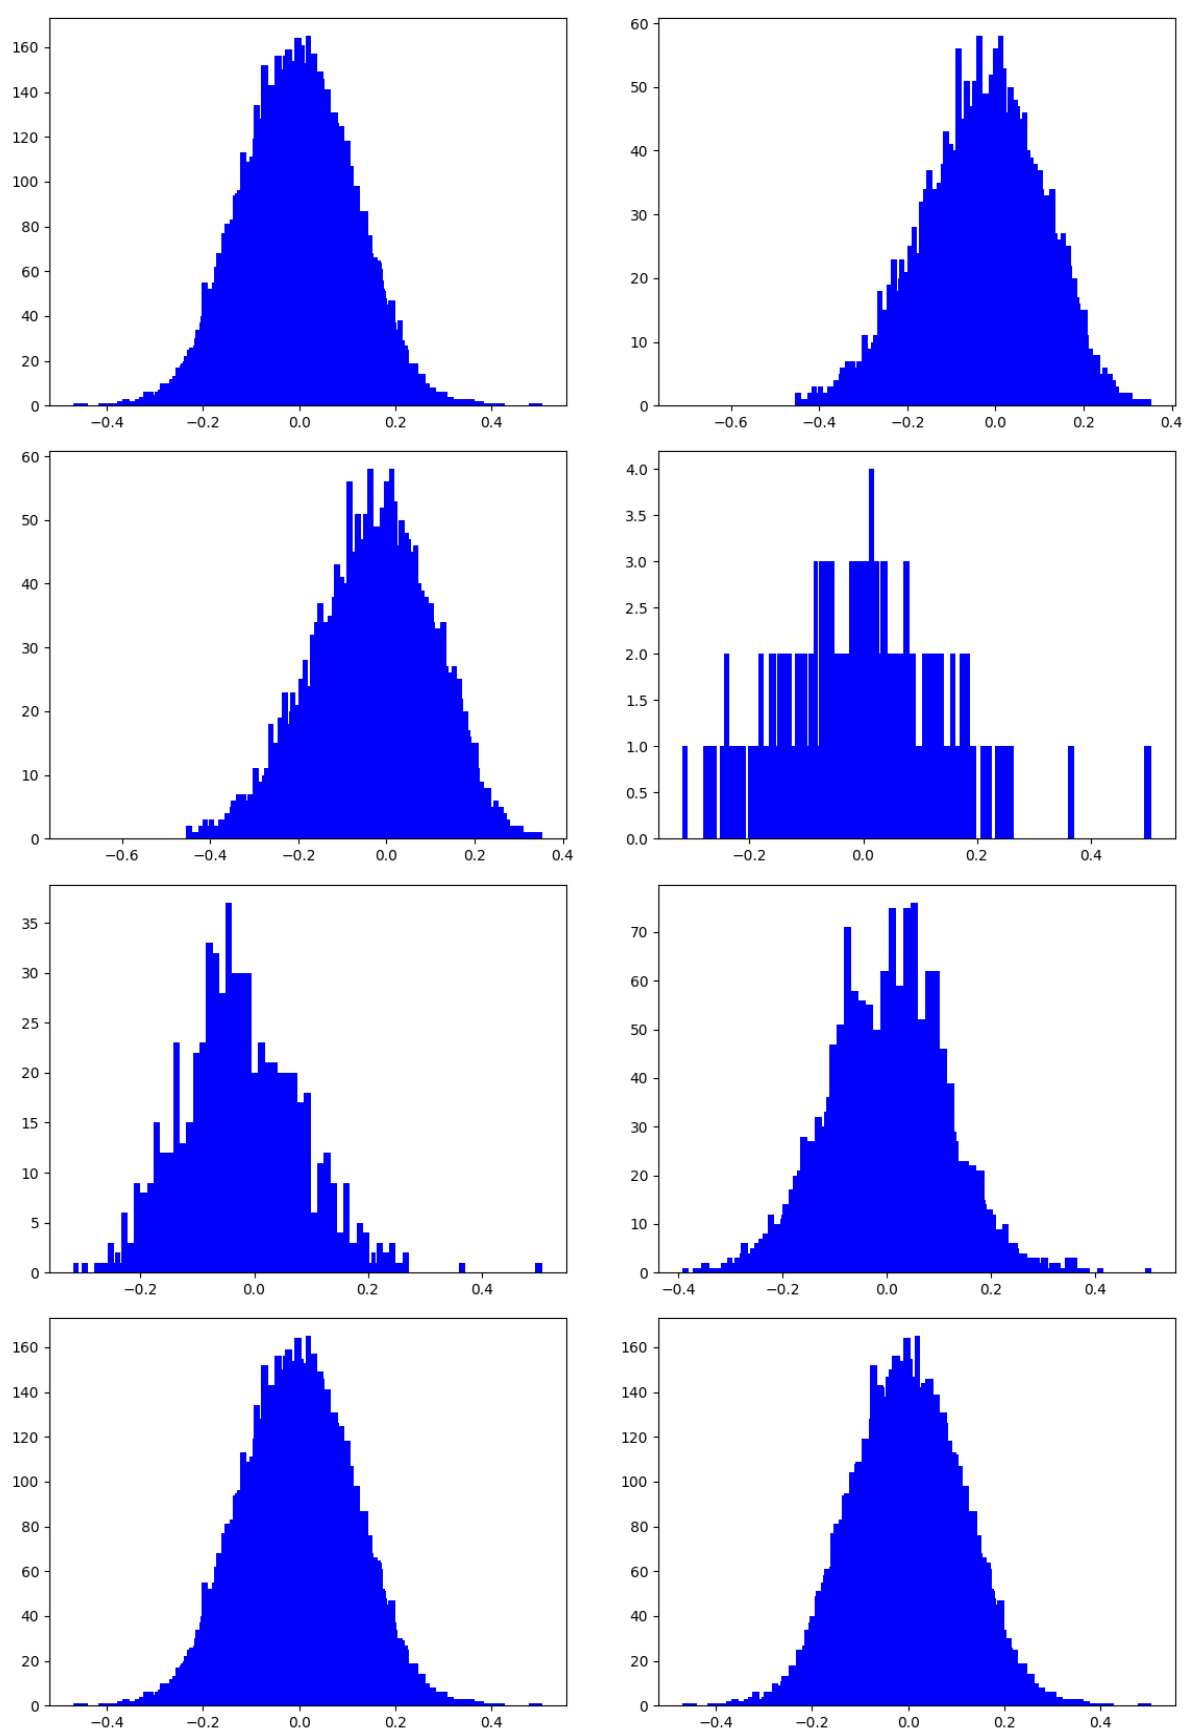


图 4-7 卷积核权值分布

本章首先计算了阈值设置为 0.1 剪枝后的稀疏度，结果是 0.66，考虑到将模型中 66% 的权值都设置为 0 会极大地影响模型的精确度，又计算了阈值设置为 0.05 剪枝后的稀疏度，结果是 0.36，本章将该值作为终止阈值。初始模型中稀疏度为 0，阈值剪枝时，将初始阈值设置为 0.01，每次将阈值增加 0.01。本章在通道剪枝后的模型上进行阈值剪枝，如图 4-8 所示。

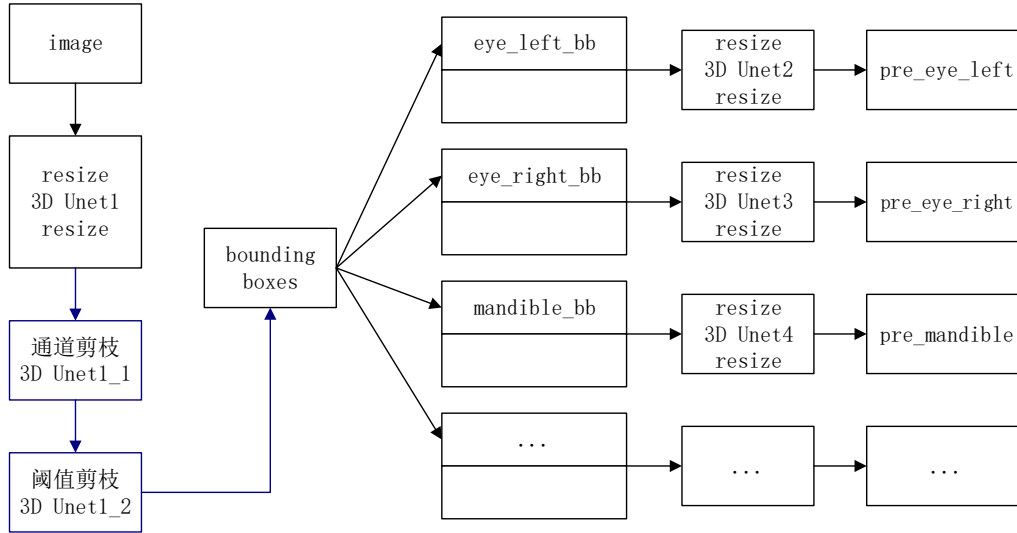


图 4-8 阈值剪枝

基于阈值剪枝算法的伪代码如下，主要分为四步：1) 设置剪枝初始阈值和终止阈值；2) 遍历待剪枝网络模型的每一层，将卷积核中小于阈值的权值置为零；3) 对神经网络进行再训练，为置为零的元素添加“掩膜”，使其不再参与反向传播，此时再训练的次數设置为 2000 次；4) 逐步增大阈值，对模型进行多次阈值剪枝，直到阈值增大到终止阈值。文中计算并对比了不同阈值下模型的稀疏性与精确度，详情见实验 4.3.1 部分，最终从剪枝后模型的稀疏性和精度两个方面考虑，选定合适的阈值。

算法 4-2 阈值迭代剪枝算法

输入： $\{w_k, 0 \leq k \leq C\}$ ：待剪枝的模型，共有 C 层；**start**：初始阈值， $\text{start}=0.01$ ；**end**：终止阈值， $\text{end}=0.05$ ；

输出： $\{w_k, 0 \leq k \leq C\}$ ：剪枝后的权重及其掩膜

Repeat

for $k = 0, 1, \dots, C$ do

将 w_k 中绝对值小于 start 的值置为零

end for

Repeat

前向传播

反向传播（计算掩膜，置为 0 的元素不参与反向传播）

Until 达到最大迭代次数

$\text{start} \leftarrow \text{start} + 0.01$ 增大剪枝率，在上一次剪枝的基础上继续剪枝

Until $\text{start} \geq \text{end}$ 持续剪枝与再训练，直到剪枝率达到 end

4.2.3 基于多值化权值量化的 3D Unet 算法

权值量化主要通过用有限的几个值表示神经网络中的参数来减小模型的存储空间。假设原来的参数用 32bit 存储，将所有参数用 8bit 存储，相当于把模型压缩了 4 倍。二值化网络是权值量化的极端情况，用+1 和-1 表示模型中的所有参数，卷积过程中所有的乘法运算用加法和取反操作替代。本文借鉴二值化权值量化的思想，对剪枝后的模型进行多值化量化，如图 4-9 所示。

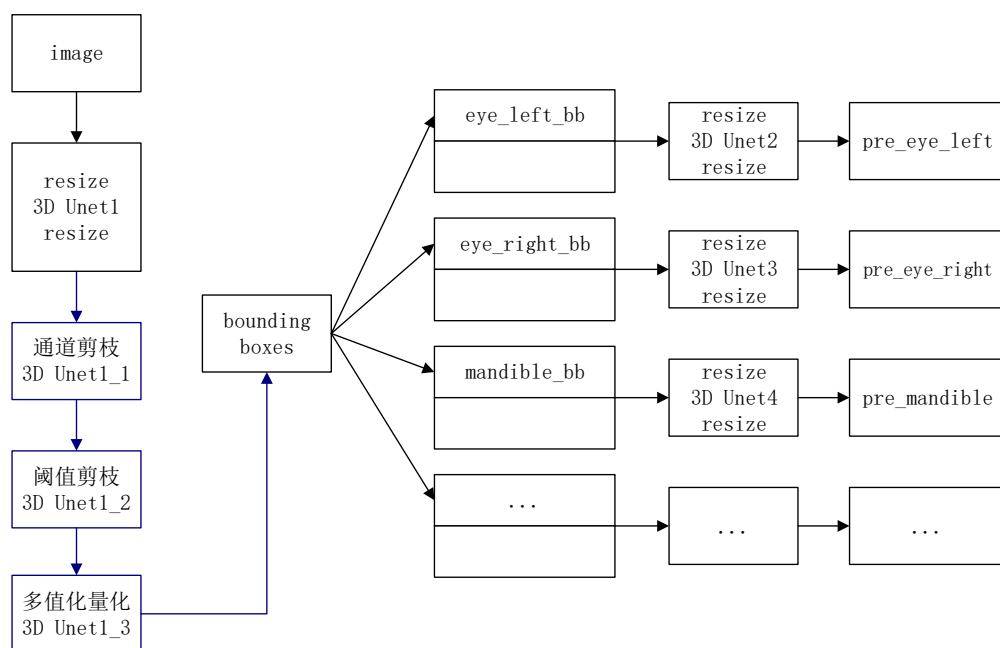


图 4-9 多值化量化

图 4-10 是二值化量化卷积示意图，第 1 列是一张 $5 \times 5 \times 3$ 的输入图像；第 2 列是 4 个 $3 \times 3 \times 3$ 的卷积核，红色一列表示原始卷积核，蓝色一列表示对原始卷积核进行二值化量化后只含有+1 和-1 权值的卷积核；第 3 列是量化后的卷积核对输入图像进行卷积得到的特征图；第 4 列是堆叠特征图得到的卷积结果。




图 4-10 二值化量化卷积示意图

二值化量化很重要的一项是确定如何进行二值化。最简单有效的方法是令所有大于等于 0 的权值为+1，小于 0 的权值为-1，如式 4-1：

$$w_b = \begin{cases} +1, & \text{if } w \geq 0 \\ -1, & \text{otherwise} \end{cases} \quad (4-1)$$

式中， w 表示卷积核中的权值， w_b 表示经过二值化后得到的新的权值。也可以将所有的权值映射到[0,1]之间，然后依概率取+1 或者-1。由于权重一般呈均值为 0 的高斯分布，因此不必做映射，直接按照式 4-1 进行二值化取值可以达到同等的效果。

二值化量化算法的伪代码如算法 4-3，分为前向传播和反向传播。前向传播中，按式 4-1 对所有卷积核进行二值化，由于二值化是为了减少乘法运算量，而 bias 本身是加法运算，因此不对 bias 进行二值化。二值化后卷积核中的权值仅含有+1 和-1，但由于特征图或输入图像是 float32 位，因此所进行的计算仍是浮点计算。反向传播时，计算权重并更新梯度。求梯度时，如式 4-2：

$$w_b' = \frac{\partial C}{\partial w_b} \quad (4-2)$$

式中， C 表示损失函数， w_b 表示二值化后的权值， w_b' 是损失函数对二值化后的权值求偏导得到的结果。权值更新时，如式 4-3：

$$w_{k1} = w_k - \mu \cdot w_b' \quad (4-3)$$

式中， w_k 是量化前卷积核的权值， w_b' 是损失函数对量化后的卷积核求偏导的结果， μ 是学习率， w_{k1} 是权值梯度更新一次得到的结果。量化操作不可微，所以不直接对量化前的权值求导。梯度更新过程中，把量化之后的权值梯度直接赋值给量化之前权值的梯度。

算法 4-3 二值化量化算法

输入： $\{w_k, b_k, 0 \leq k \leq L\}$ ：待量化的模型，共有 L 层； C ：损失函数； μ ：学习率；

输出： $\{w_k, b_k, 0 \leq k \leq L\}$ ：量化后的模型

1) 前向传播

for $k = 1$ to L do

$w_b \leftarrow \text{binarize}(w_k)$ 对卷积核权值进行二值化，不对 bias 进行二值化

$z_k \leftarrow w_b \times a_{k-1} + b_k$ 中间值

$a_k \leftarrow \sigma(z_k)$ 激活函数

end for

2) 反向传播

$\frac{\partial C}{\partial a_L}$ 计算输出层激活值的偏导数

for $k = L$ to 2 do

$\frac{\partial C}{\partial z_k} = \frac{\partial C}{\partial a_k} \cdot \sigma'(z_k)$

$\frac{\partial C}{\partial a_{k-1}} = (w_k)^T \cdot \frac{\partial C}{\partial z_k}$

$\frac{\partial C}{\partial w_b} = \frac{\partial C}{\partial z_k} \cdot (a_{k-1})^T$ 计算 w_b 的梯度，即：对 w_k 量化之后的梯度

算法 4-3 (续)

$$\frac{\partial C}{\partial b_k} = \frac{\partial C}{\partial a_k} \text{ 计算 } b_k \text{ 的梯度}$$

$$w_k \leftarrow w_k - \mu \frac{\partial C}{\partial w_b} \text{ 更新 } w_k, \text{ 相当于把量化之后的梯度赋值给了量化之前的梯度}$$

$$b_k \leftarrow b_k - \mu \frac{\partial C}{\partial b_k} \text{ 更新 } b_k$$

end for

分析图 4-7 权值分布图可知：卷积核的权值较小，大都分布在-0.4 到 0.4 之间，接近 0 的权值数量非常多，且有关于 0 对称的趋势。所以，本文将量化重心放在区间：[-0.45, +0.45]。本文首先对剪枝后的模型进行了二值化权值量化（二值化公式如 4-1），得到的结果很不理想。考虑到可能是权值精度太低引起的，本文又分别对模型进行了三值化、七值化、十五值化和三十一值化权值量化。其中，三值化公式如 4-4，取间隔为 0.3 (0.9÷3)，将大于 0.15 的值量化为 1，小于-0.15 的值量化为-1，-0.15 和 0.15 之间的值量化为 0。

$$w_b = \begin{cases} +1, & \text{if } w > 0.15 \\ 0, & \text{if } -0.15 \leq w \leq 0.15 \\ -1, & \text{if } w < -0.15 \end{cases} \quad (4-4)$$

式中， w 表示卷积核中的权值， w_b 表示经过三值化后得到的新的权值。

五值化量化公式如式 4-5，取间隔为 0.18 (0.9÷5)：

$$w_b = \begin{cases} 0.27, & \text{if } w > 0.27 \\ 0.09, & \text{if } 0.09 < w \leq 0.27 \\ 0, & \text{if } -0.09 \leq w \leq 0.09 \\ -0.09, & \text{if } -0.27 \leq w < -0.09 \\ -0.27, & \text{if } w < -0.27 \end{cases} \quad (4-5)$$

式中， w 表示卷积核中的权值， w_b 表示经过五值化后得到的新的权值。

七值化量化公式如式 4-6，取间隔为 0.13 (0.9÷7)：

$$w_b = \begin{cases} 0.325, & \text{if } w > 0.325 \\ 0.195, & \text{if } 0.195 < w \leq 0.325 \\ 0.065, & \text{if } 0.065 < w \leq 0.195 \\ 0, & \text{if } -0.065 \leq w \leq 0.065 \\ -0.065, & \text{if } -0.195 \leq w < -0.065 \\ -0.195, & \text{if } -0.325 \leq w < -0.195 \\ -0.325, & \text{if } w < -0.325 \end{cases} \quad (4-6)$$

式中， w 表示卷积核中的权值， w_b 表示经过七值化后得到的新的权值。

十五值化和三十一值化权值量化以此类推，十五值化的间隔为 0.06 (0.9÷15)，三十一值化的间隔为 0.03 (0.9÷31)。本文对比了不同值化量化下模型的精度和内存占用，详情见章节 4.3.2。

4.3 实验结果与分析

4.3.1 通道剪枝对模型运行内存及速度的影响

为了得到最佳的通道剪枝率，本文设计了以下对比实验：首先，以 5% 的剪枝率对模型进行通道剪枝、重训练 2000 次；然后，对剪枝后的模型再次以 5% 的剪枝率进行通道剪枝、重训练 2000 次；直到总的剪枝率到达 25% 停止。表 4-2 中列出了每层卷积核所占用的内存大小以及剪枝后该层卷积核所占用的内存大小，随着剪枝率的增加，卷积核所占用内存是越来越少的。

表 4-2 不同通道剪枝率与参数大小 (KB)

操作	shape	0	5%	10%	15%	20%	25%
conv3d_1	3×3×3×1×24	2.5	2.4	2.3	2.2	2.1	1.9
conv3d_2	3×3×3×24×24	60	56	51	47	42	34
conv3d_3	3×3×3×24×48	121	112	102	91	82	68
conv3d_4	3×3×3×48×48	243	223	204	177	160	137
conv3d_5	3×3×3×48×96	486	446	404	355	317	273
conv3d_6	3×3×3×96×96	972	893	798	709	625	547
conv3d_7	3×3×3×96×192	1944	1776	1587	1418	1251	1094
conv3d_8	3×3×3×192×192	3888	3532	3157	2837	2501	2187
t_conv3d_1	2×2×2×192×96	576	526	470	420	371	324
conv3d_9	3×3×3×192×96	1944	1776	1587	1418	1251	1094
conv3d_10	3×3×3×96×96	972	893	798	709	625	547
t_conv3d_2	2×2×2×96×48	144	132	120	105	94	81
conv3d_11	3×3×3×96×48	486	446	404	355	317	273
conv3d_12	3×3×3×48×48	243	223	204	177	160	137
t_conv3d_3	2×2×2×48×24	36	33	30	27	24	20
conv3d_13	3×3×3×48×24	121	112	102	91	82	68
conv3d_14	3×3×3×24×24	60	56	51	47	42	34
conv3d_15	3×3×3×24×9	23	23	23	23	23	23
sum	/	12.03M	11.00M	9.86M	8.80M	7.78M	6.78M

实验中记录了不同剪枝率下模型分割的精确度（第一阶段分割出的八个器官精确度的平均值），如图 4-11 所示，横坐标是相对于初始模型的剪枝率，纵坐标是分割的平均精确度。当剪枝率为 25% 时，精确度下降约 0.042；当剪枝率为 20% 时，剪枝率下降约 0.016；本文选择剪枝率为 20% 的模型作为最终通道剪枝模型，此时，模型平均分割精度降低约 0.016；卷积核占用的内存大小为 7.78M，压缩率为 35.3%；模型运行时占用的内存由原来的 3G 降到了 2G；模型运行时间减少了 10s。




图 4-11 不同剪枝率下分割精度

4.3.2 阈值剪枝对模型稀疏度的影响

为了增加模型的稀疏性，配合硬件存储、加速相关工作，在通道剪枝的基础上进行了阈值剪枝。为了获取最佳的阈值对模型进行阈值剪枝，本文进行了以下对比实验：首先，设置阈值为 0.01，对通道剪枝后的模型进行阈值剪枝、重训练 2000 次；然后，将阈值增加 0.01，再次对模型进行阈值剪枝、重训练 2000 次，直到阈值达到 0.05。

实验中记录了不同阈值剪枝下模型分割的精确度，如图 4-12 所示，横坐标是相对于初始模型（通道减枝后的模型）的剪枝率，纵坐标是分割的平均精确度。当阈值设置为 0.01 进行剪枝和重训练后，模型分割精确度可以恢复到剪枝前；当阈值设置为 0.02 进行剪枝和重训练后，精确度下降约 0.004；当阈值设置为 0.03 进行剪枝和重训练后，精确度下降约 0.004；当阈值设置为 0.04 进行剪枝和重训练后，精确度下降 0.045。本文选择阈值为 0.02 的剪枝结果作为最终结果。




图 4-12 不同阈值下分割精度

本文从模型分割精确度、内存占用、运行时间以及稀疏度四个方面对比了模型剪枝前后的结果。如表 4-3 所示，通道剪枝在损失 0.016 分割精确度的情况下，把模型压缩了 35.3%，把模型的运行时间减少了 10s；阈值剪枝是在通道剪枝后的模型上进行的，

在损失了 0.004 分割精确度的情况下，把模型稀疏度提高到了 0.15。

表 4-3 剪枝前后对比

指标	原模型	通道剪枝	阈值减枝
精确度	0.670	0.654	0.650
内存占用	12.03M	7.78M	/
运行时内存占用	3G	2G	/
运行时间	30s	20s	/
稀疏度	0	/	0.150

4.3.3 量化对模型体积的影响

为了得到合适的量化参数，本文分别对剪枝后的模型进行了二值化、三值化、七值化、十五值化和三十一值化权值量化实验，经过不同值化权值量化后，卷积核的内存占用量（硬件上）和模型分割精确度如表 4-4 所示。当对模型进行二值化、三值化和七值化量化时，很大程度地降低了模型的体积，但是模型的分割精度下降太多；本文最终对剪枝后的模型进行三十一值化权值量化，配合硬件存储可将模型的体积降至 1.9M，而模型的精确度仅降低 0.004。

表 4-4 不同权值量化对比

值化	卷积核内存占用	精确度
原模型	7.78M	0.650
二值化	0.24M	0.231
三值化	0.49M	0.272
七值化	0.78M	0.382
十五值化	0.97M	0.539
三十一值化	1.9M	0.646

本文将原模型与剪枝量化后的模型从精确度、内存占用、运行时间和稀疏度四个方面进行了比较，如表 4-5。通过对基于 3D Unet 头颈部 CT 图像器官分割算法第一阶段模型进行剪枝和量化，整个模型运行时间减少了 10s，稀疏度提高到了 0.15。实验证明，第一阶段损失的 0.024 的分割精确度，没有影响到第二阶段各个器官的分割结果。

表 4-5 原模型与剪枝量化后模型对比

指标	原模型	剪枝量化
精确度	0.670	0.646
内存占用	12.03M	1.9M
运行时间	30s	20s
稀疏度	0	0.150

4.4 本章小结

本章主要是对基于 3D Unet 头颈部 CT 图像器官分割算法模型压缩的研究。对第一阶段用于定位的网络模型从通道剪枝、阈值剪枝和多值化量化三个方面进行压缩，压缩后的模型体积大大减小，只有原本的 $1/6$ ；模型的运行时间减少了 10s；模型的稀疏度为 0.15。由于第一阶段的网络仅用于器官的定位，第二阶段的网络会对器官进行更加精细的分割，本章的模型压缩仅将第一阶段网络模型的精确度降低了 0.024，实验表明，这不会导致各个器官最终分割精度的下降。

5 结论与展望

5.1 结论

放疗是治疗头颈部肿瘤的主要方法，放射治疗的第一步是勾画出危及器官的轮廓，以便放疗师制定合理的照射剂量方案，减少对正常组织的损伤。一般由医生手动勾画出危及器官的轮廓，但 CT 图像是由 100 张左右二维图像堆叠而成的三维图像，手工勾画非常繁琐且耗时。为了减少医生的工作量，提高放射治疗的工作效率，研究头颈部 CT 图像危及器官自动分割算法变得非常重要。近年来，已证明基于深度学习的分割算法比传统的分割算法具有更好的性能。本文基于深度学习分割框架 3D Unet 研究头颈部 CT 图像器官自动分割。

1) 提出一种基于 3D Unet 头颈部 CT 图像器官分割算法。首先，针对头颈部 CT 图像软组织对比度不明显，器官在整张 CT 图像上占比小的问题，引入 Two Stage 训练与分割流程，第一阶段一次性分割出所有的器官，第二阶段提取第一阶段分割结果的 bounding box，再分别对不同的器官进行训练与分割，整体提升各个器官分割的精确度。其次，考虑到以下两点原因：卷积深数过大会导致模型中参数过多引起过拟合，而卷积深数过小会导致模型中参数过少引起欠拟合；池化次数过多会导致丢失器官重要信息，而池化次数过少会导致模型“视野”较小分割能力差，本文修改了原始 3D Unet 网络模型中的卷积层数和池化次数，得到了一个适合头颈部 CT 图像器官分割的 3D Unet。同时，使用 focal loss 损失函数替代交叉熵损失函数，弥补因器官大小、体积等差异性大引起的分割精度差异性大的问题。最后，在本文数据集和 MICCAI 公开数据集上对比了本章算法和其他分割算法，实验结果表明：本章算法相比于其他算法有更好的分割效果。

2) 提出基于模型压缩的 3D Unet 头颈部 CT 图像器官分割算法。仅对第一阶段用于定位的网络模型进行压缩，压缩后的模型体积大大减小，只有原来的 1/6；模型运行时占用的内存由 3G 降到了不足 2G；模型的运行时间减少了 10s；模型的稀疏度为 0.15。在模型压缩过程中，首先对模型进行了通道剪枝，剪去了对分割结果影响较小的卷积核，将模型的体积从 12.03M 减少到了 7.78M，模型的运行时间减少了 10s。然后，又对剪枝后的模型进行了阈值剪枝，提高了模型的稀疏度，配合硬件存储和加速相关工作，阈值剪枝在损失了 0.004 分割精度的情况下，将模型的稀疏度从 0 提升到了 0.15。最后，对剪枝后的模型进行了量化，减少模型存储时占用的位数，配合硬件加速工作，将模型的体积从 7.78M 减少到了 1.9M。由于第一阶段的网络仅用于器官的定位，第二阶段的网络会对器官进行更加精细的分割，实验结果表明：第一阶段（器官定位）网络模型由于模型压缩降低的 0.024 的精确度，不会影响第二阶段各个器官更加精细的分割，即：器官最终的分割精确度不变。

5.2 展望

本文基于 3D Unet 对头颈部 CT 图像器官分割进行研究，通过改进原始 3D Unet 的卷积深度、池化次数和损失函数得到了一个适合头颈部 CT 图像器官分割的模型，通过引入 Two Stage 训练与分割流程，极大的提升了模型的分割精确度；针对模型运行时占用内存大、耗时的问题，本文对神经网络进行了模型压缩。本文算法在相应的测量标准中均有不错的表现，但是仍存在以下的不足：

1) 本文采用 Two Stage 训练与分割流程，虽然极大的提升了分割的精确度，但由于第二阶段需要训练八个小网络模型，导致训练过程非常耗时，未来将对八个小网络模型特征复用进行研究。

2) 为了不损失模型的分割精度，本文仅对第一阶段的网络模型进行了压缩，未来将对第二阶段八个网络模型进行压缩。

致 谢

为其三年的硕士生活就要结束，我即将步入社会。我的人生观、价值观在交大这个温暖的氛围里得到了完善与巩固，相比三年前，我更加自信、乐观与温柔，我成为了更好的自己。如今，感慨良多，想对我的老师及同学们致以最诚挚的谢意。

首先，我要感谢我的导师田丽华老师。疫情期间在家撰写毕业论文，每次遇到问题在 QQ 上问田老师，不管是周内还是周末，她总能及时回复我的消息并给出恰当的建议，帮助我顺利地完成了论文。与田老师的每次对话都让我觉得很温暖，她从不会让自己的学生感觉到尴尬。在每周组会上，与田丽华老师和李晨老师的进度汇报和讨论，都让我收获很多。

其次，我要感谢上海大图医疗科技有限公司的同事，特别是我的校外导师王文化。研二一年的实习期间，我在王文化经理的引领和指导下，研发了头颈部 CT 图像器官分割算法，该算法目前已经应用于很多家医院，而且我的毕业论文也基于实习项目展开。王文化经理是我的职业启蒙老师，我会牢记他的教诲：你所做的每一件事都是在书写自己的简历。

然后，我要感谢我的父母。当初，父亲一直鼓励我读研，没有他的支持就没有今天的我。父母给我和弟弟营造了一个温馨幸福的家庭氛围，让我们可以无后顾之忧地追逐自己的梦想。处于人生的低谷时，想到还有他们可以依靠，我就充满了力量。每次遇到挫折，幽默的父母总会逗我开心，鼓励我勇往直前。我也会努力成长，早日成为他们的依靠。

最后，我要感谢我亲爱的同学们。找工作时，有很多热心的师兄师姐帮忙内推；平时遇到问题，同学们也都会耐心的帮助和指导，这些都让我感觉到交大这个大家庭的温暖。通过与不同性格、专业的同学相处，我更加明确了对自己的定位，找到了自己与社会之间的平衡点。

感谢你们，未来，我会更加努力，成为更好的自己。

参考文献

- [1] Torre L A, Bray F I, Siegel R L, et al. Global cancer statistics, 2012[J]. CA: A Cancer Journal for Clinicians, 2015, 65(2): 87-108.
- [2] 梁淑君. 基于卷积神经网络的鼻咽癌放射治疗危及器官分割方法研究[D]. 南方医科大学, 2019.
- [3] Z. E. Rosenblatt E, “Radiotherapy in cancer care: Facing the global challenge,” International Atomic Energy Agency, Tech. Rep., 2017.
- [4] 田娟秀, 刘国才, 谷珊珊等. 基于 3D 深度残差全卷积网络的头颈 CT 放疗危及器官自动勾画[J]. 中国生物医学工程学报, 2019, 38(03): 257-265.
- [5] Harari P M, Song S, Tome W A, et al. Emphasizing Conformal Avoidance Versus Target Definition for IMRT Planning in Head-and-Neck Cancer[J]. International Journal of Radiation Oncology Biology Physics, 2010, 77(3): 950-958.
- [6] 阴晓娟, 胡彩容, 张秀春等. 基于图谱库的 ABAS 自动勾画软件在头颈部肿瘤中的可行性研究[J]. 中华放射肿瘤学杂志, 2016, 25(11): 1233-1237.
- [7] Nikolov S, Blackwell S, Mendes R, et al. Deep learning to achieve clinically applicable segmentation of head and neck anatomy for radiotherapy[J]. Computer Vision and Pattern Recognition, 2018.
- [8] Fortunati V, Verhaart R F, Der Lijn F V, et al. Tissue segmentation of head and neck CT images for treatment planning: a multiatlas approach combined with intensity modeling.[J]. Medical Physics, 2013, 40(7).
- [9] H. Duc, K. Albert, G. Eminowicz, et al. “Validation of clinical acceptability of an atlas-based segmentation algorithm for the delineation of organs at risk in head and neck cancer,” Med. Phys., vol. 42, no. 9, pp. 5027–5034, 2015.
- [10] 邓金城, 彭应林, 刘常春. 深度卷积神经网络在放射治疗计划图像分割中的应用. 中国医学物理学杂志, 2018, 35(6): 621-627.
- [11] Ronneberger O, Fischer P, Brox T, et al. U-Net: Convolutional Networks for Biomedical Image Segmentation[C]. medical image computing and computer assisted intervention, 2015: 234-241.
- [12] De Fauw J, Ledsam J R, Romeraparedes B, et al. Clinically applicable deep learning for diagnosis and referral in retinal disease[J]. Nature Medicine, 2018, 24(9).
- [13] Fritscher K D, Raudaschl P, Zaffino P, et al. Deep Neural Networks for Fast Segmentation of 3D Medical Images[C]. medical image computing and computer assisted intervention, 2016: 158-165.
- [14] A. Hänsch, M. Schwier, T. Gass, et al. “Comparison of different deep learning approaches for parotid gland segmentation from CT images,” in Med Imaging Comp-Aided Diag, vol. 10575. International Society for Optics and Photonics, Feb. 2018, p. 1057519.
- [15] Zhu W, Huang Y, Tang H, et al. AnatomyNet: Deep 3D Squeeze-and-excitation U-Nets for fast and fully automated whole-volume anatomical segmentation[J]. bioRxiv, 2018.
- [16] Tong N, Gou S, Yang S, et al. Fully automatic multi-organ segmentation for head and neck cancer radiotherapy using shape representation model constrained fully convolutional neural networks[J]. Medical Physics, 2018, 45(10): 4558-4567.
- [17] 戴相昆, 王小深, 杜乐辉等. 基于三维 U-NET 深度卷积神经网络的头颈部危及器官的自动勾

画[J/OL]. 生物医学工程学杂志: 1-6[2020-03-14].

- [18] 陈才. 基于最优 Atlas 的 CT 影像中肺叶精准分割算法研究[D]. 湘潭大学, 2019.
- [19] H. Xu, A. Arsene Henry, M. Robillard, et al. "The use of new delineation tool Mirada at the level of regional lymph nodes, step-by-step development and first results for early-stage breast cancer patients," The British journal of radiology, 2018.
- [20] Buzug S T. Relaxed Statistical Shape Models for 3D Image Segmentation – Application to Mandible Bone in Cone-beam CT Data[J]. Current Medical Imaging Reviews, 2013, 9(2): 129-137.
- [21] Fritscher K D, Peroni M, Zaffino P, et al. Automatic segmentation of head and neck CT images for radiotherapy treatment planning using multiple atlases, statistical appearance models, and geodesic active contours.[J]. Medical Physics, 2014, 41(5): 051910-051910.
- [22] Chen A, Noble J H, Niermann K J, et al. Segmentation of parotid glands in head and neck CT images using a constrained active shape model with landmark uncertainty[J]. Proceedings of SPIE, 2012.
- [23] Qazi A A, Pekar V, Kim J, et al. Auto-segmentation of normal and target structures in head and neck CT images: A feature-driven model-based approach[J]. Medical Physics, 2011, 38(11): 6160-6170.
- [24] Ma G, Gao Y, Wu G, et al. Nonlocal atlas-guided multi-channel forest learning for human brain labeling. Medical physics. 2016; 43(2):1003–1019.
- [25] Wachinger C, Brennan M, Sharp G C, et al. Efficient Descriptor-Based Segmentation of Parotid Glands With Nonlocal Means[J]. IEEE Transactions on Biomedical Engineering, 2017, 64(7): 1492-1502.
- [26] Long J, Shelhamer E, Darrell T, et al. Fully convolutional networks for semantic segmentation[C]. computer vision and pattern recognition, 2015: 3431-3440.
- [27] Goodfellow I, Pougetabadi J, Mirza M, et al. Generative Adversarial Nets[C]. neural information processing systems, 2014: 2672-2680.
- [28] Tong N, Gou S, Yang S, et al. Fully automatic multi-organ segmentation for head and neck cancer radiotherapy using shape representation model constrained fully convolutional neural networks[J]. Medical Physics, 2018, 45(10): 4558-4567.
- [29] Ibragimov B, Xing L. Segmentation of organs-at-risks in head and neck CT images using convolutional neural networks[J]. Medical physics, 2017, 44(2):547-557.
- [30] Men K, Geng H, Cheng C, et al. More accurate and efficient segmentation of organs-at-risk in radiotherapy with convolutional neural networks cascades [J]. Medical Physics, 2018, 46(1): 286-292.
- [31] Cicek O, Abdulkadir A, Lienkamp S S, et al. 3D U-Net: Learning Dense Volumetric Segmentation from Sparse Annotation[C]. medical image computing and computer assisted intervention, 2016: 424-432.
- [32] Milletari F, Navab N, Ahmadi S, et al. V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation[C]. international conference on 3d vision, 2016: 565-571.
- [33] Ioffe S, Szegedy C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift[C]. international conference on machine learning, 2015: 448-456.
- [34] 纪荣嵘, 林绍辉, 晁飞等. 深度神经网络压缩与加速综述[J]. 计算机研究与发展, 2018, 55(09): 1871-1888.
- [35] Han S, Mao H, Dally W J, et al. Deep Compression: Compressing Deep Neural Networks with Pruning, Trained Quantization and Huffman Coding[J]. Computer Vision and Pattern Recognition, 2015.
- [36] 曹文龙, 芮建武, 李敏. 神经网络模型压缩方法综述[J]. 计算机应用研究, 2019, 36(03): 649-656.

- [37] 李江昀, 赵义凯, 薛卓尔等. 深度神经网络模型压缩综述[J]. 工程科学学报, 2019, 41(10): 1229-1239.
- [38] Lo S B, Lou S L, Lin J, et al. Artificial convolution neural network techniques and applications for lung nodule detection[J]. IEEE Transactions on Medical Imaging, 1995, 14(4): 711-718.